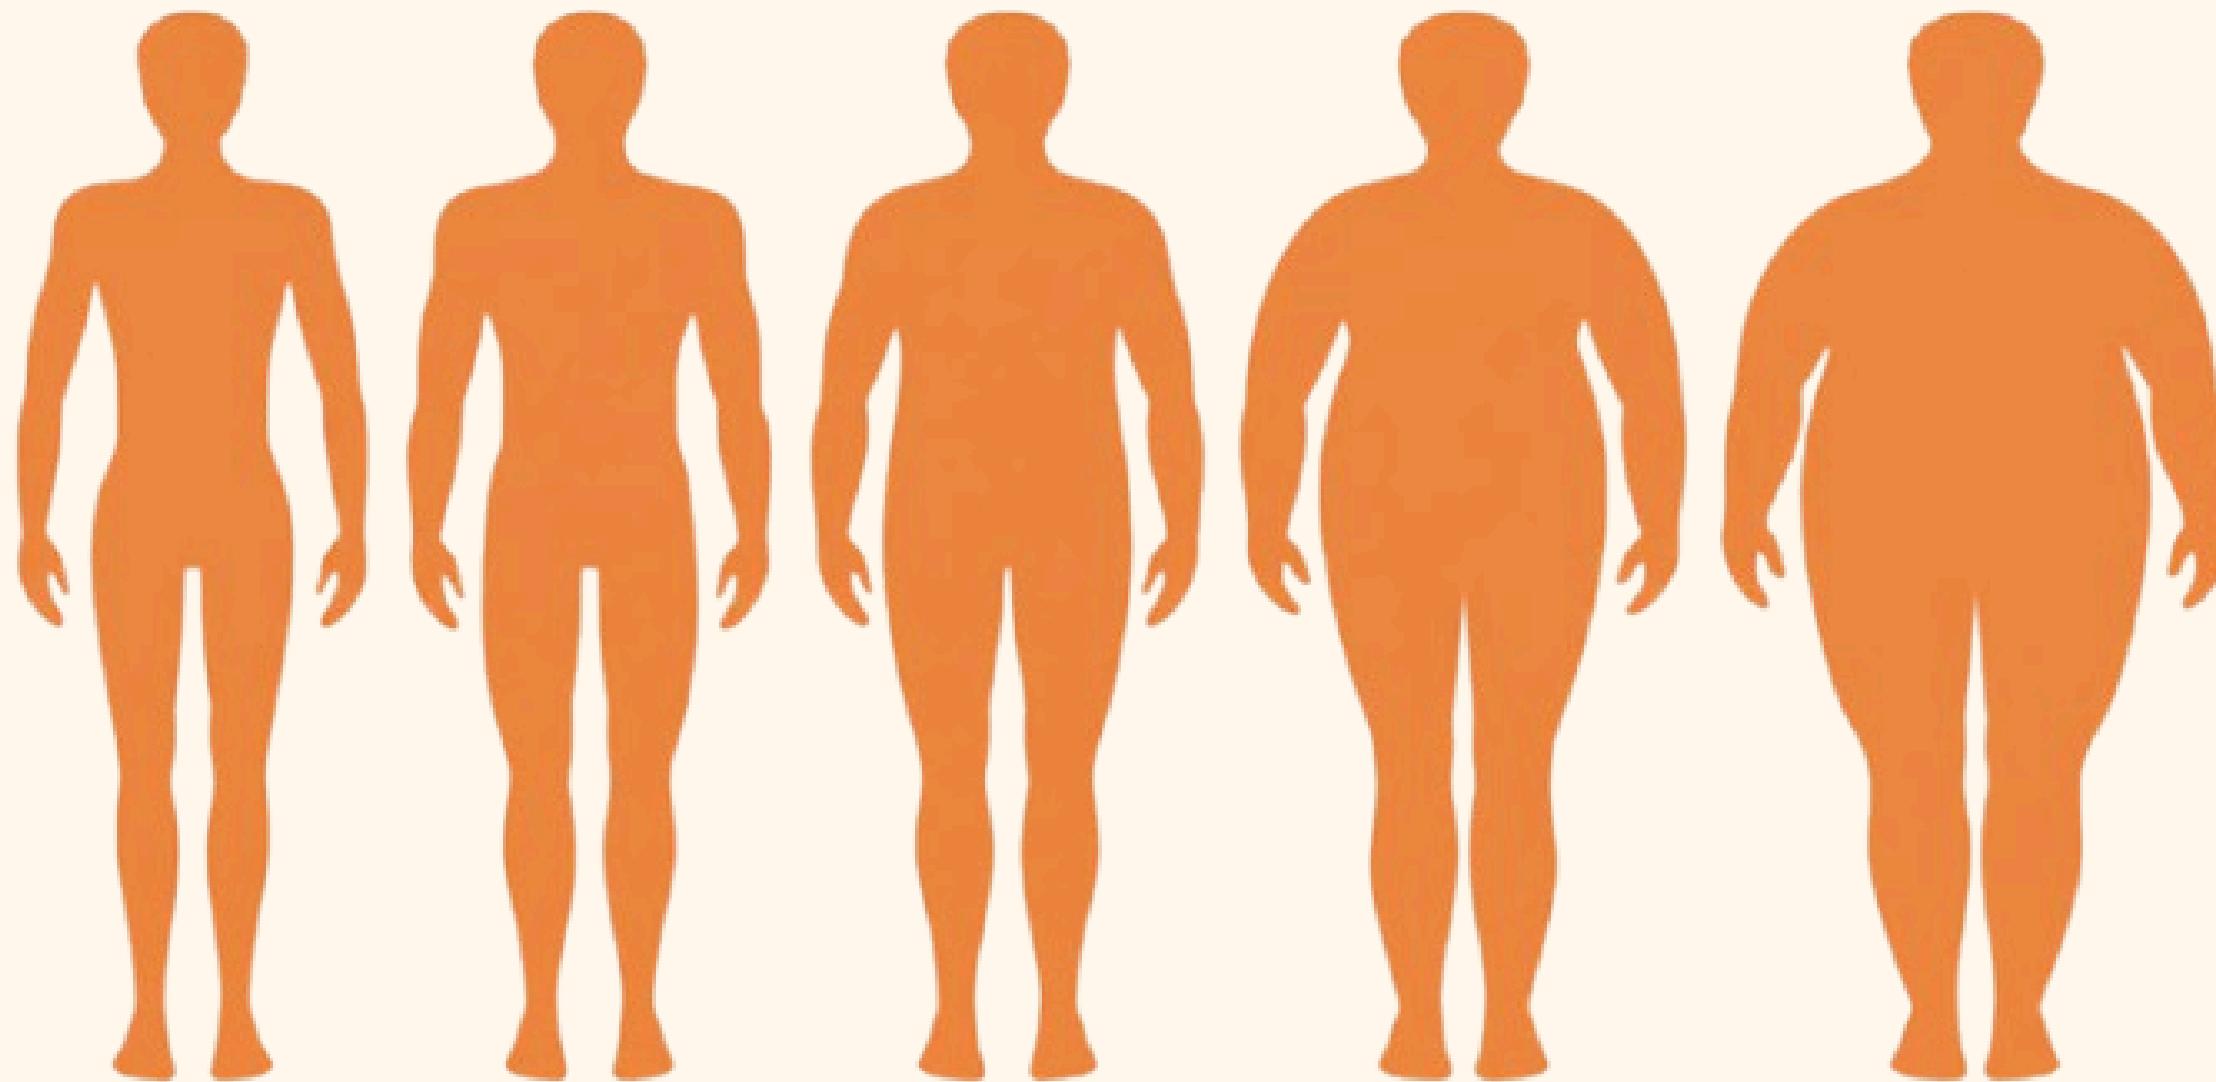
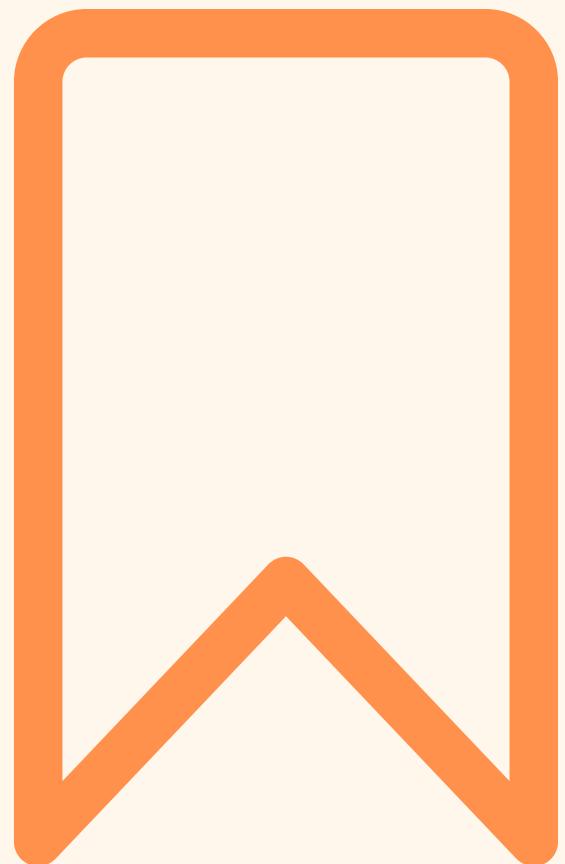


ANALISI E CLASSIFICAZIONE DELL'OBESITÀ TRAMITE DATI COMPORTAMENTALI E FISICI



INDICE



1

OBIETTIVO

2

DATASET
Spiegazione
e visualizzazione

3

CLASSIFICAZIONE
Algoritmo e risultati

4

VALUTAZIONE
del modello

OBIETTIVO

Effettuare un'analisi dei dati relativi allo stile di vita, alle abitudini dietetiche e ai parametri fisici di un gruppo di persone. Lo scopo è determinare quali specifici tratti e comportamenti sono predittivi di una diagnosi di obesità. In seguito, sviluppare un modello di machine learning capace di classificare gli individui esaminati in due gruppi distinti: normopeso e obeso



COSA RAPPRESENTA IL DATASET?



Il dataset in questione contiene dati su oltre 2 mila individui descrivendo caratteristiche fisiche, abitudini alimentari e comportamentali legate allo stile di vita. Le feature includono indicatori come frequenza dell'attività fisica, consumo di cibi calorici, idratazione e utilizzo della tecnologia. Il target categorizza gli individui in due categorie:

- **Sottopeso e normopeso con 0**
- **Sovrappeso e obeso con 1**

DATASET

2111 ISTANZE 16 FEATURES



Feature categoriche

FCVC	frequenza consumo verdure
NCP	numero pasti giornalieri
CH2O	frequenza consumo di acqua
CAEC	consumo di cibo tra i pasti
FAF	frequenza attività fisica
TUE	frequenza uso dispositivi tecnologici
MTRANS	mezzo di trasporto utilizzato maggiormente
CALC	frequenza consumo di alcolici

Feature continue

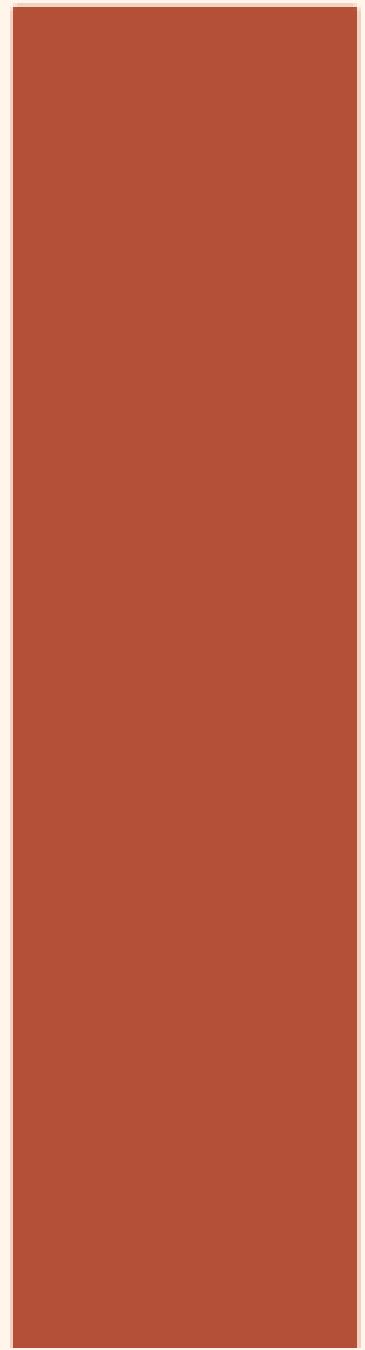
ETÀ ALTEZZA PESO

Feature binarie

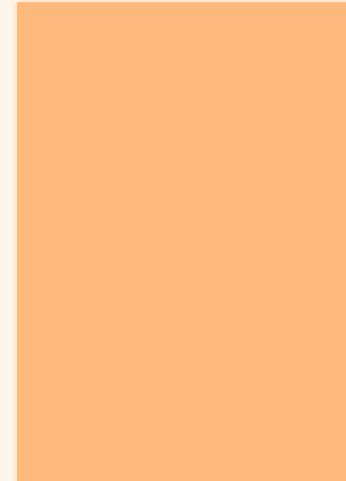
Storia familiare con sovrappeso	se un membro della famiglia ha sofferto o soffre di obesità o sovrappeso
SCC	controllo delle calorie giornaliero
SMOKE	fa utilizzo di sigarette
FAVC	consumo di cibi altamente calorici
GENERE	maschio / femmina

TARGET

1552

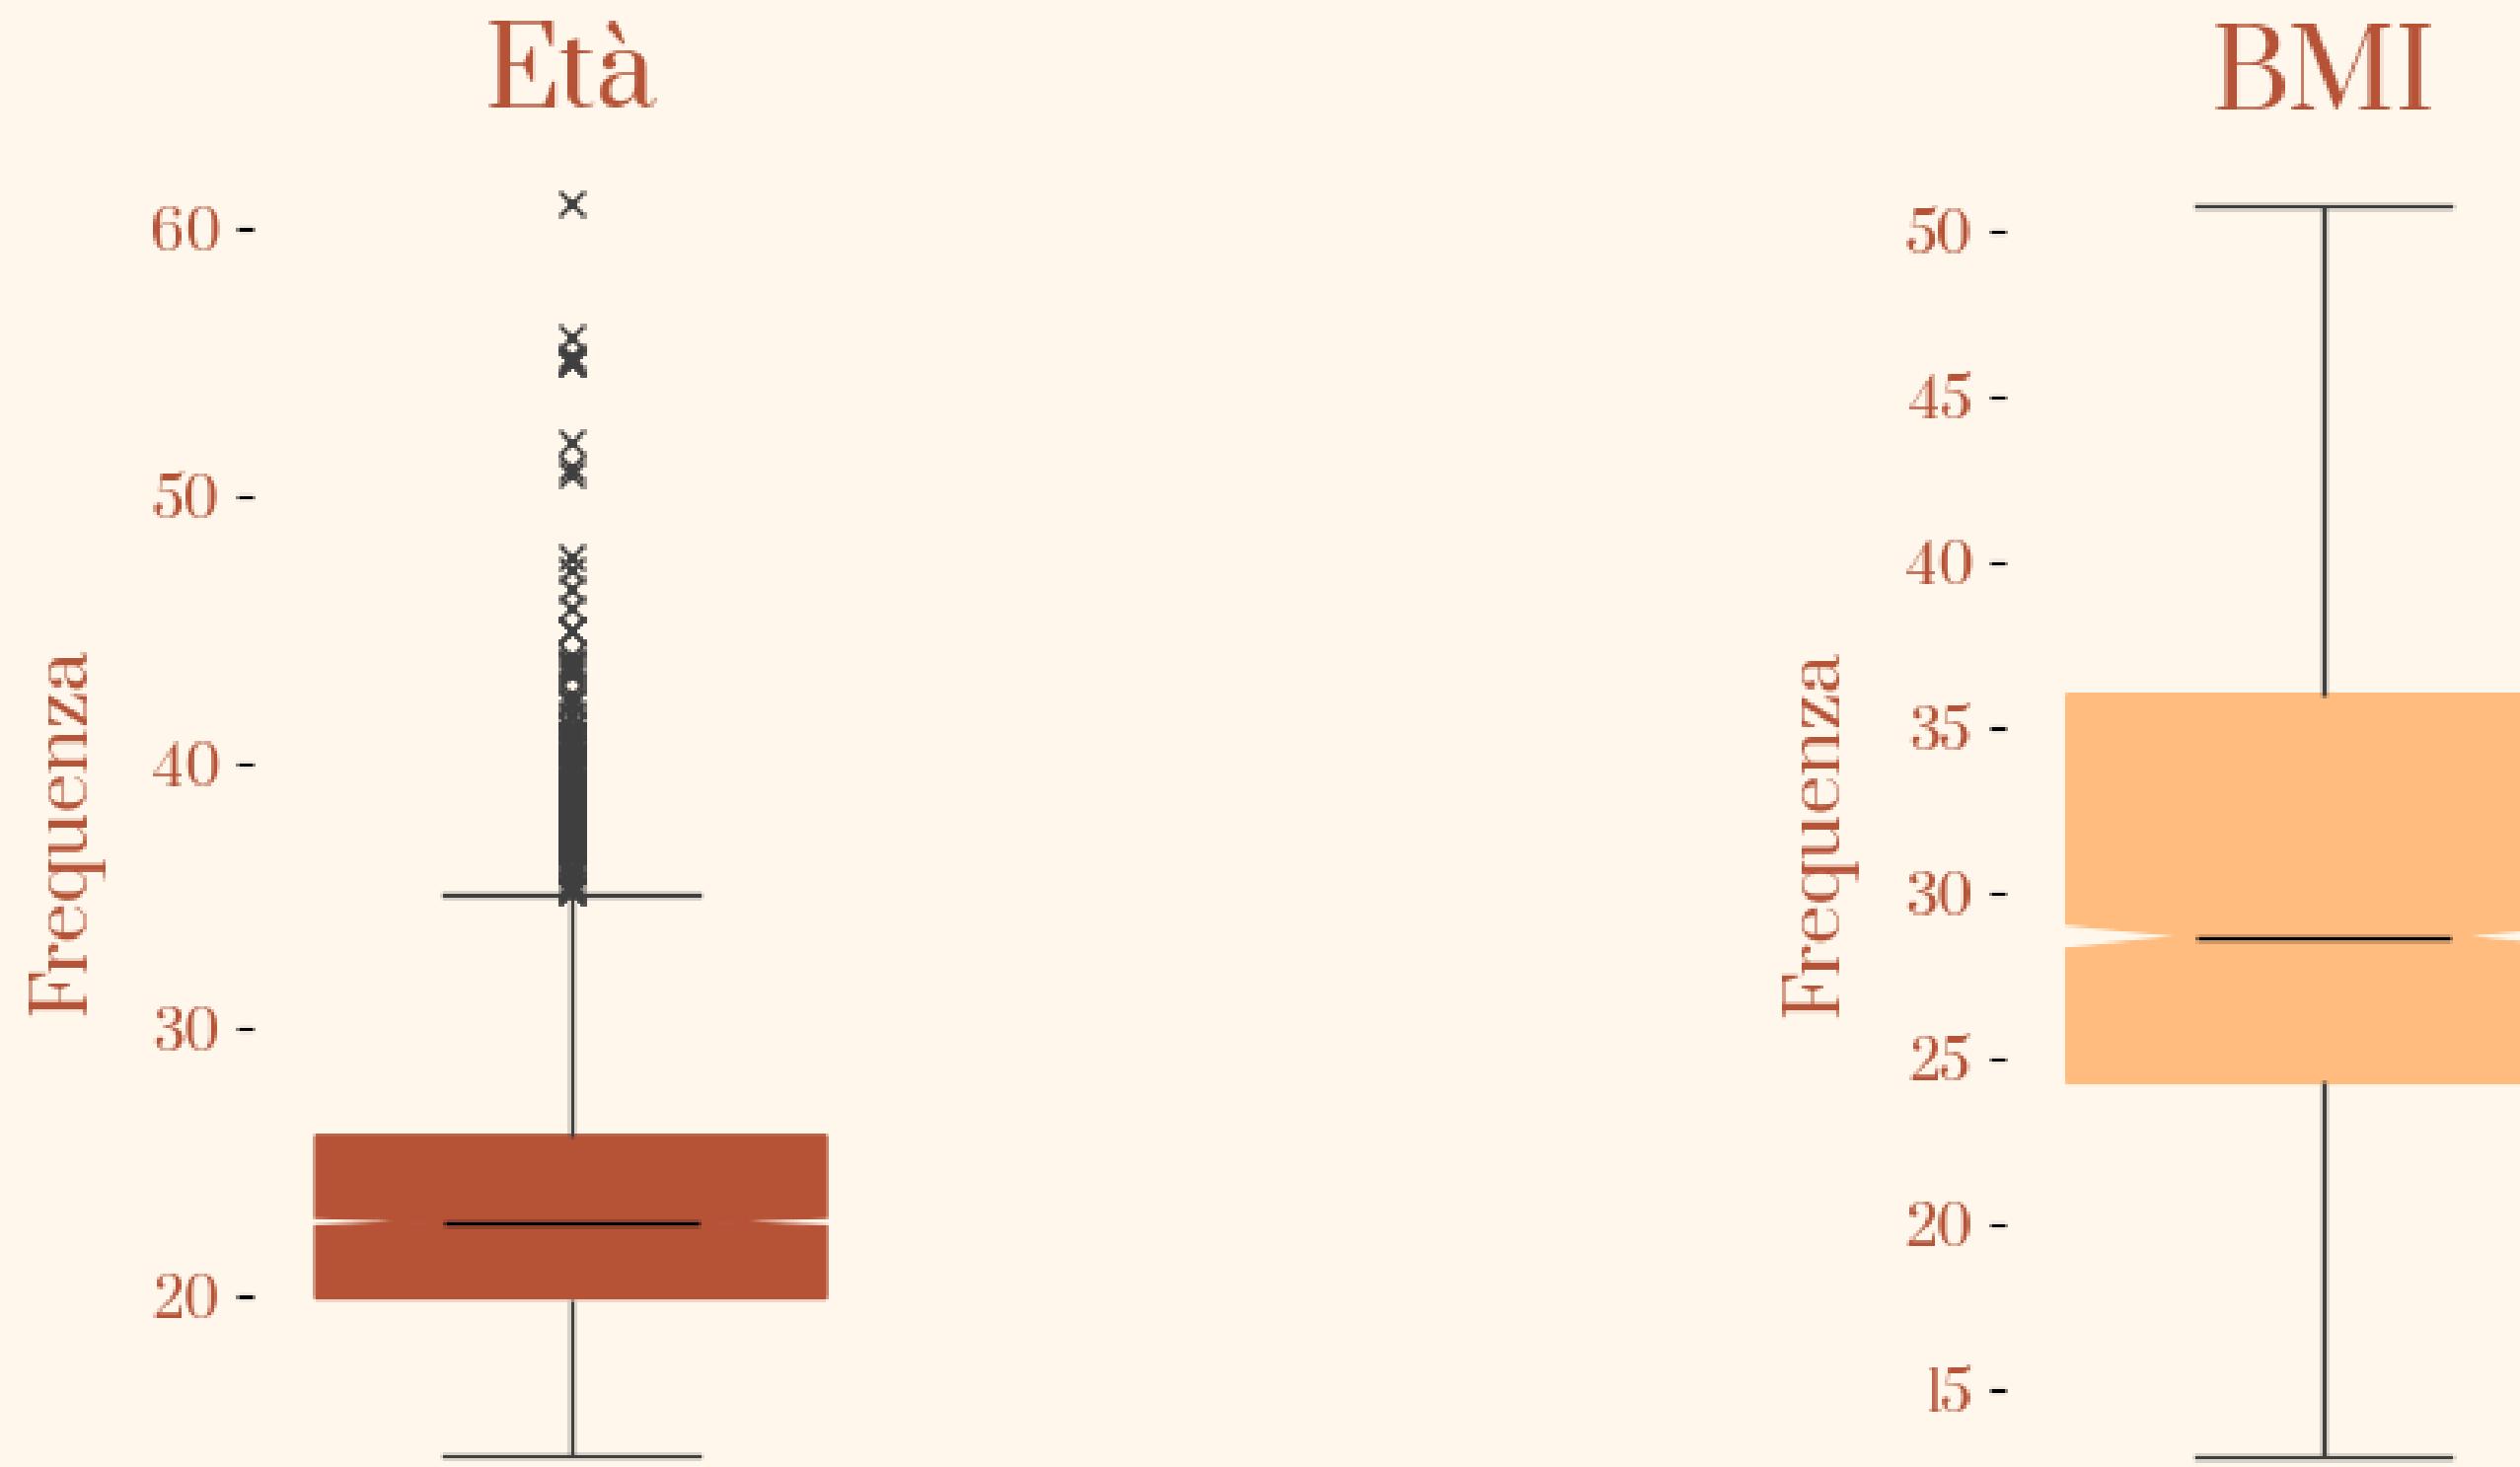


559

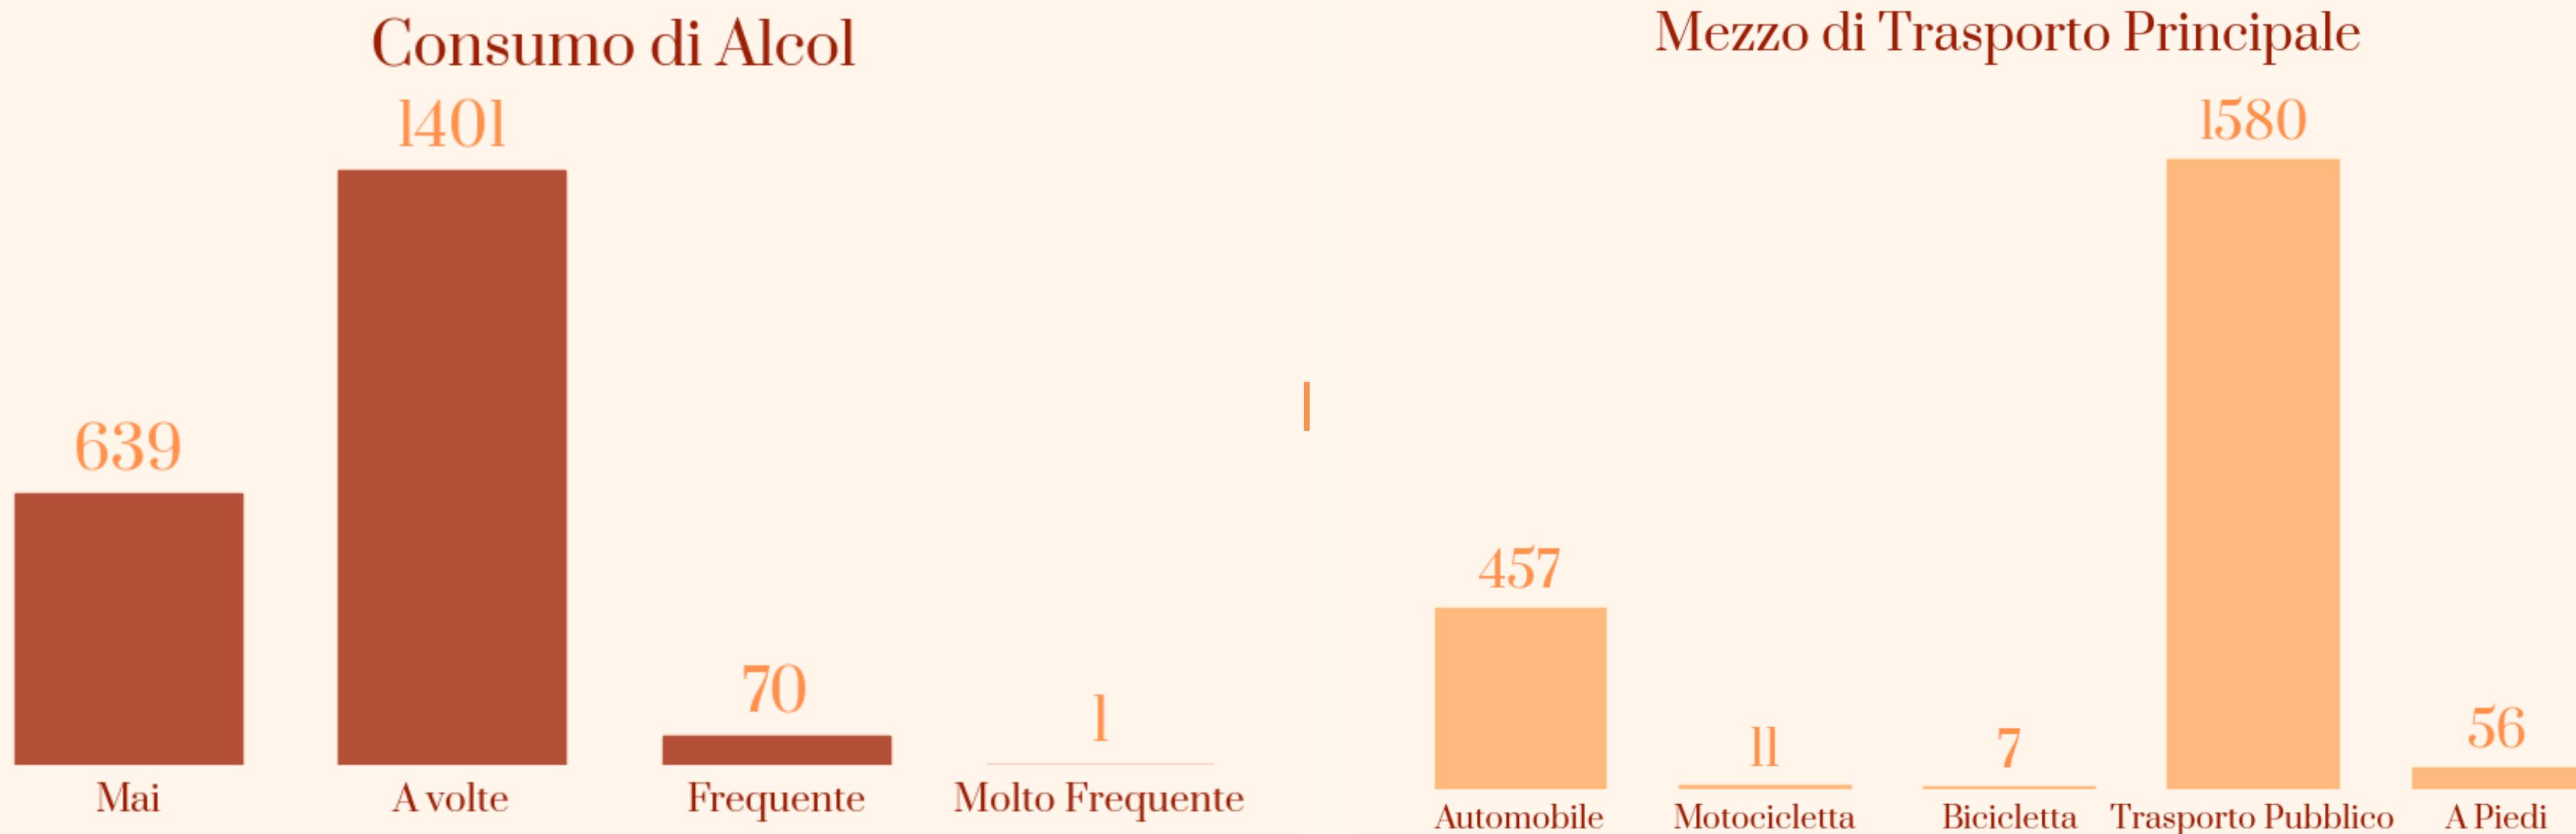


Sovrappeso/Obeso Normopeso/Sottopeso

FEATURE CONTINUE

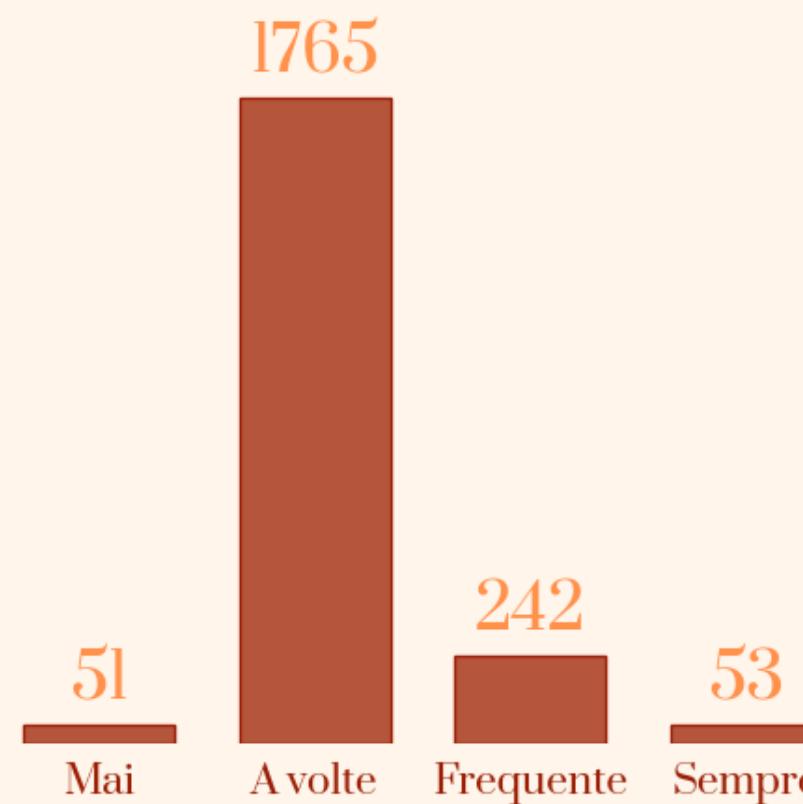


FEATURE CATEGORICHE

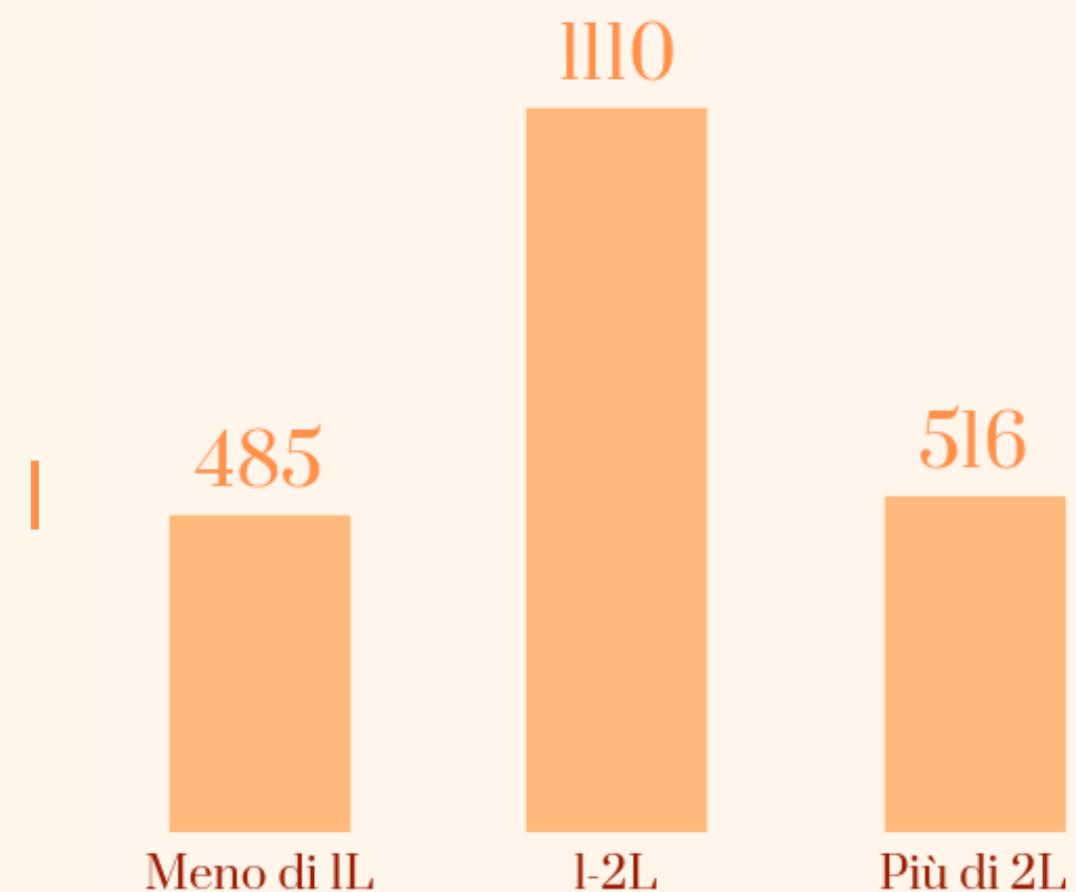


FEATURE CATEGORICHE

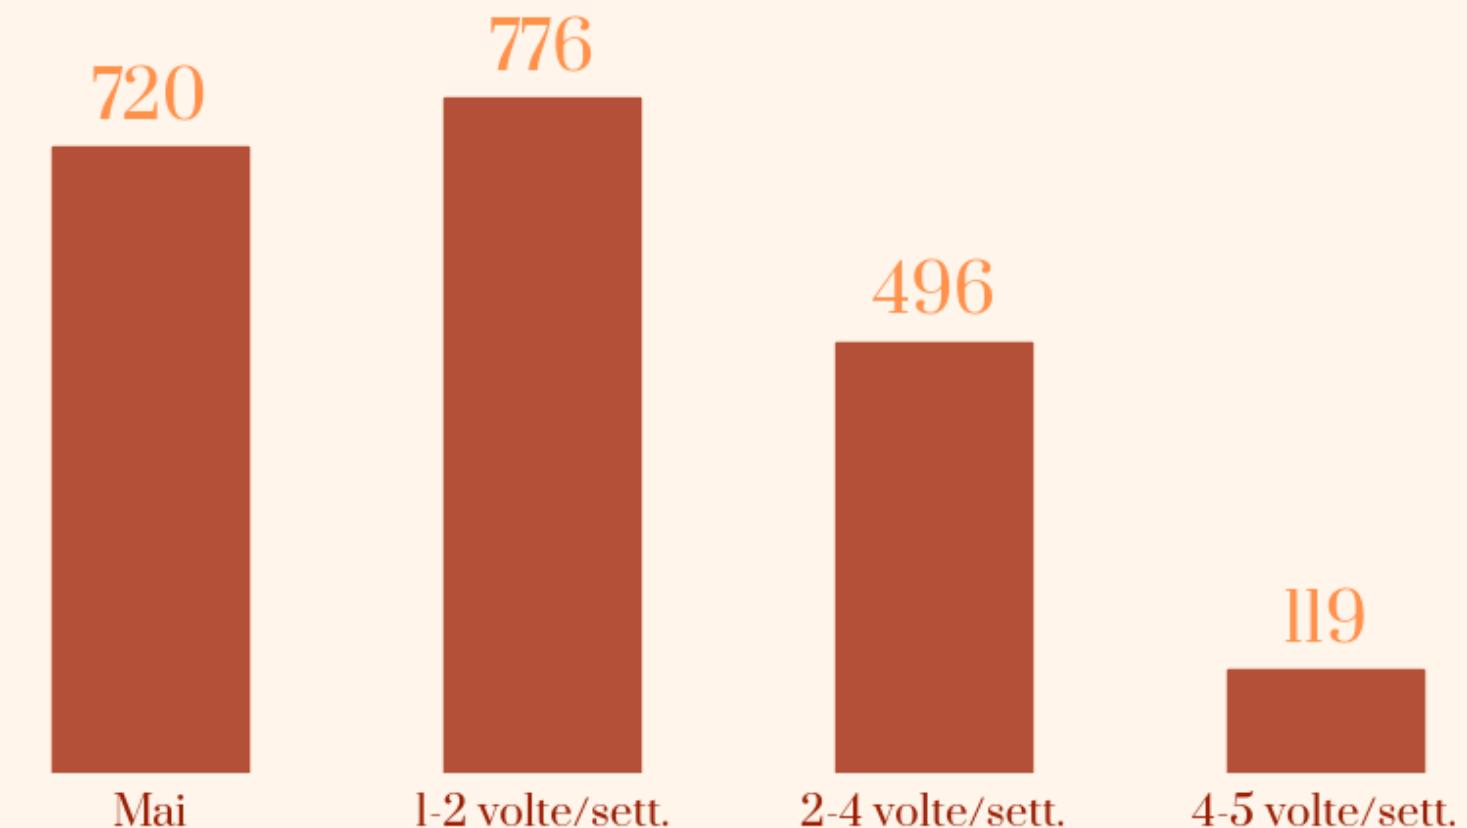
Consumo di Alimenti tra i Pasti



Consumo d'Acqua

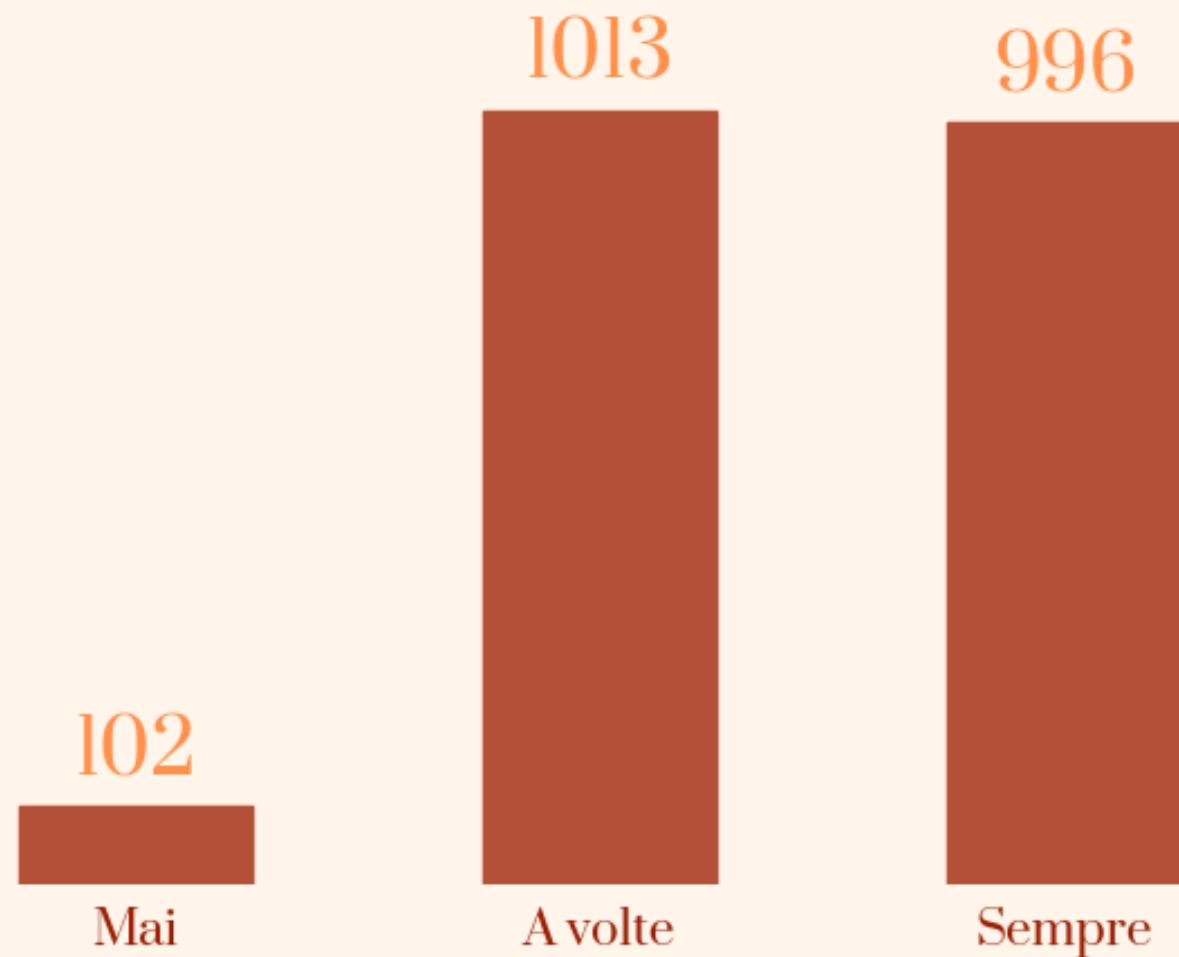


Frequenza Attività Fisica

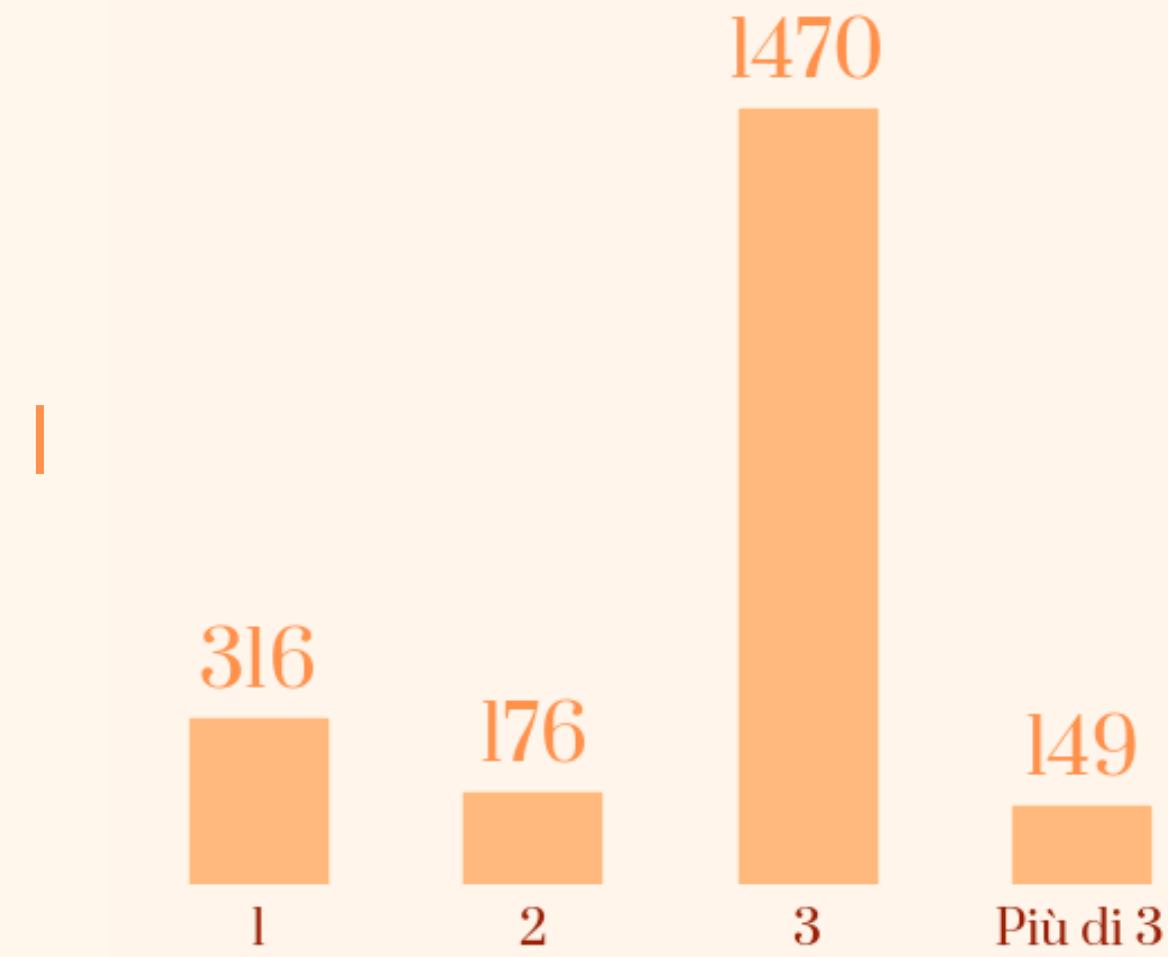


FEATURE CATEGORICHE

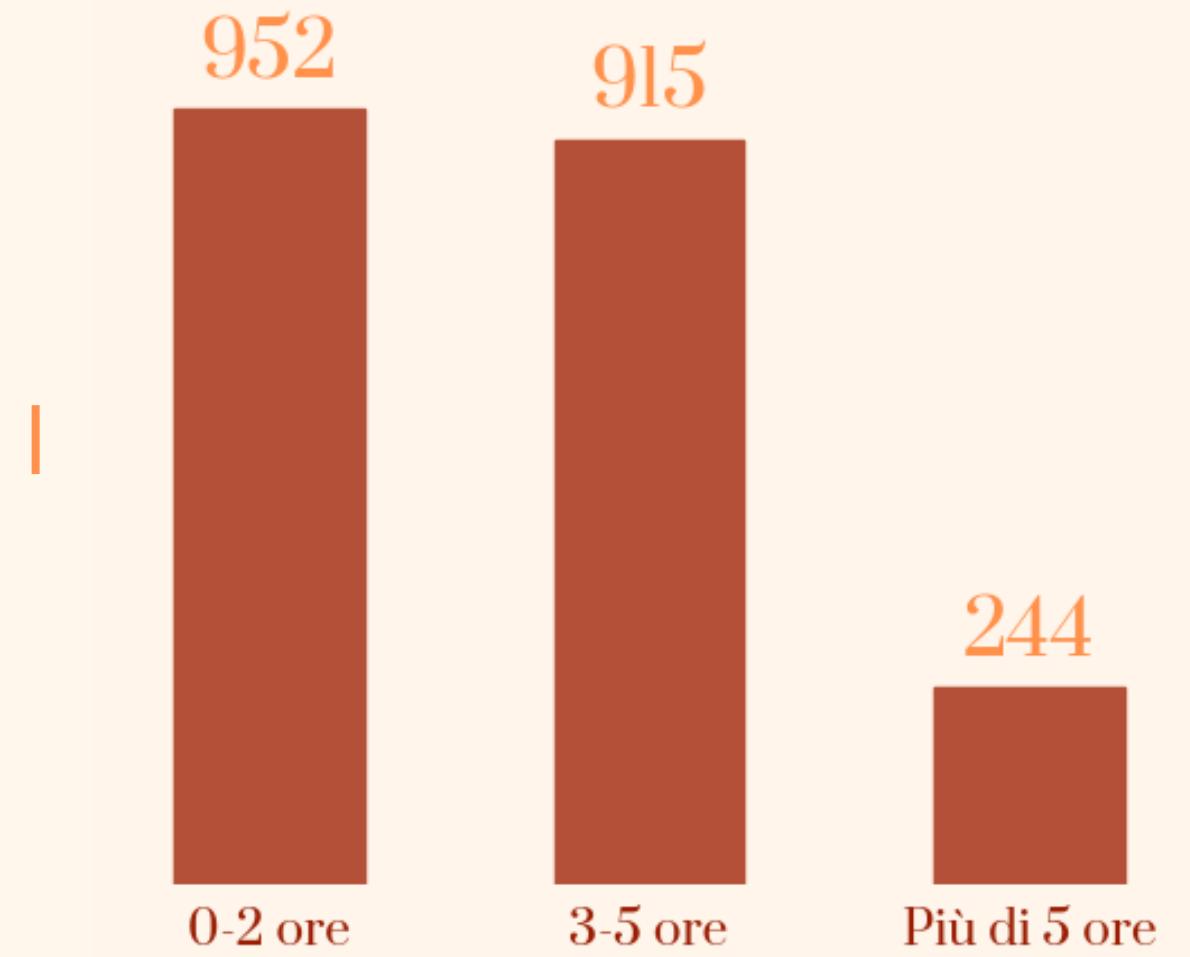
Frequenza Consumo di Vegetali



Numero di Pasti Principali



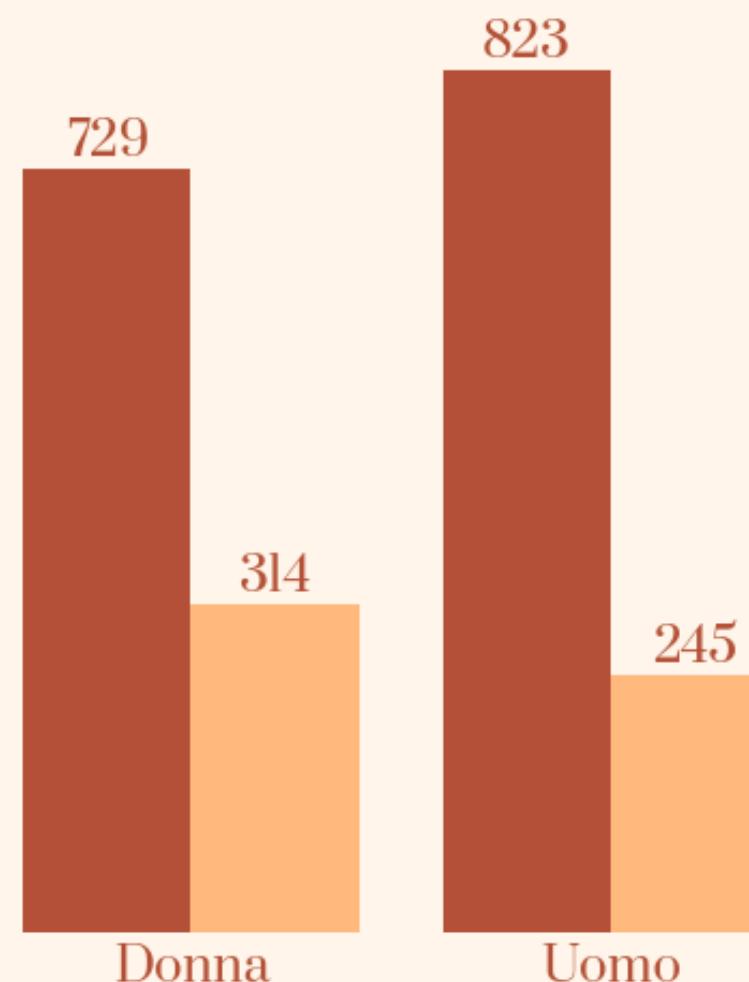
Uso di Dispositivi Tecnologici



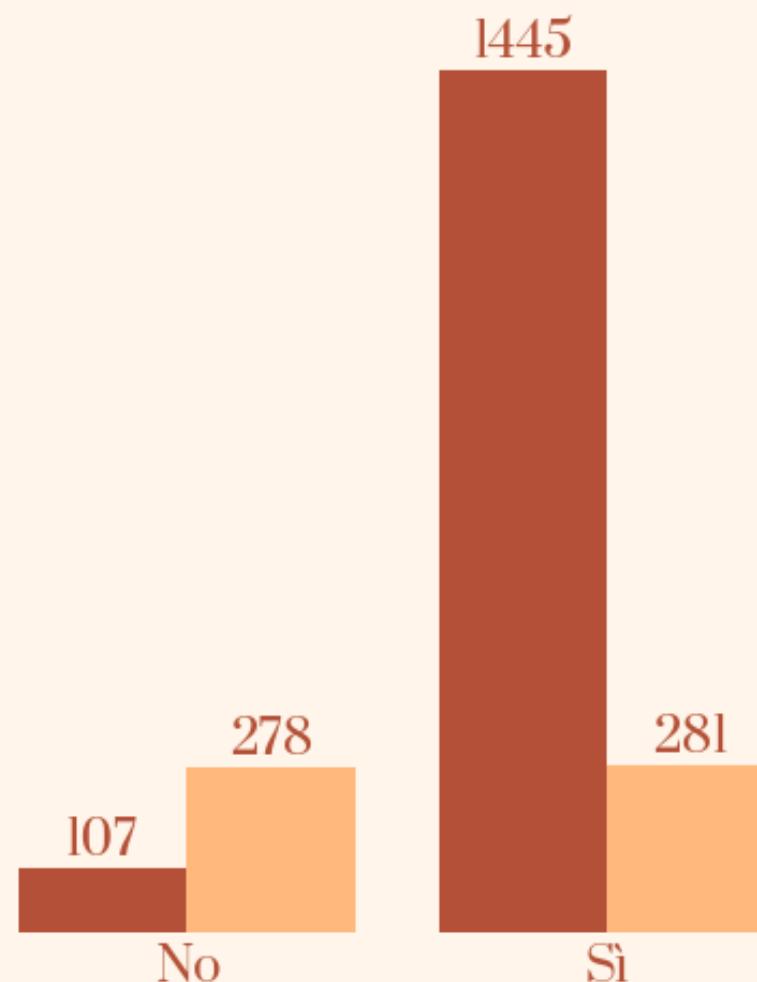
FEATURE BINARIE

Categoria
■ Sovrappeso/Obeso
■ Normopeso/Sottopeso

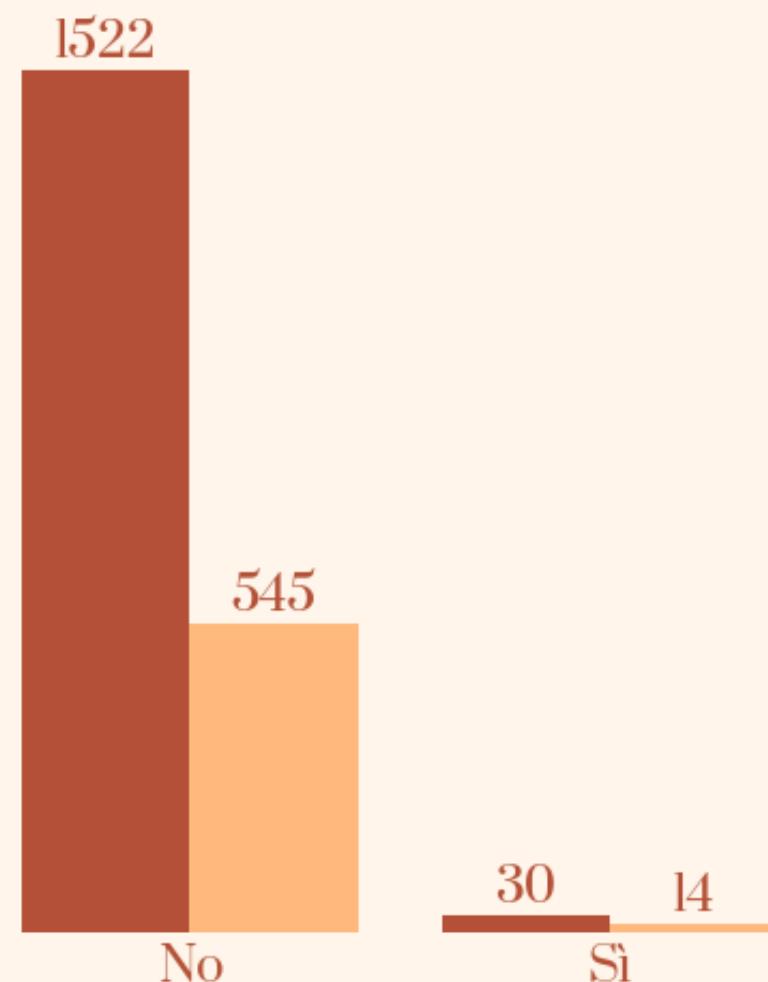
Genere



Famiglia con storia di obesità



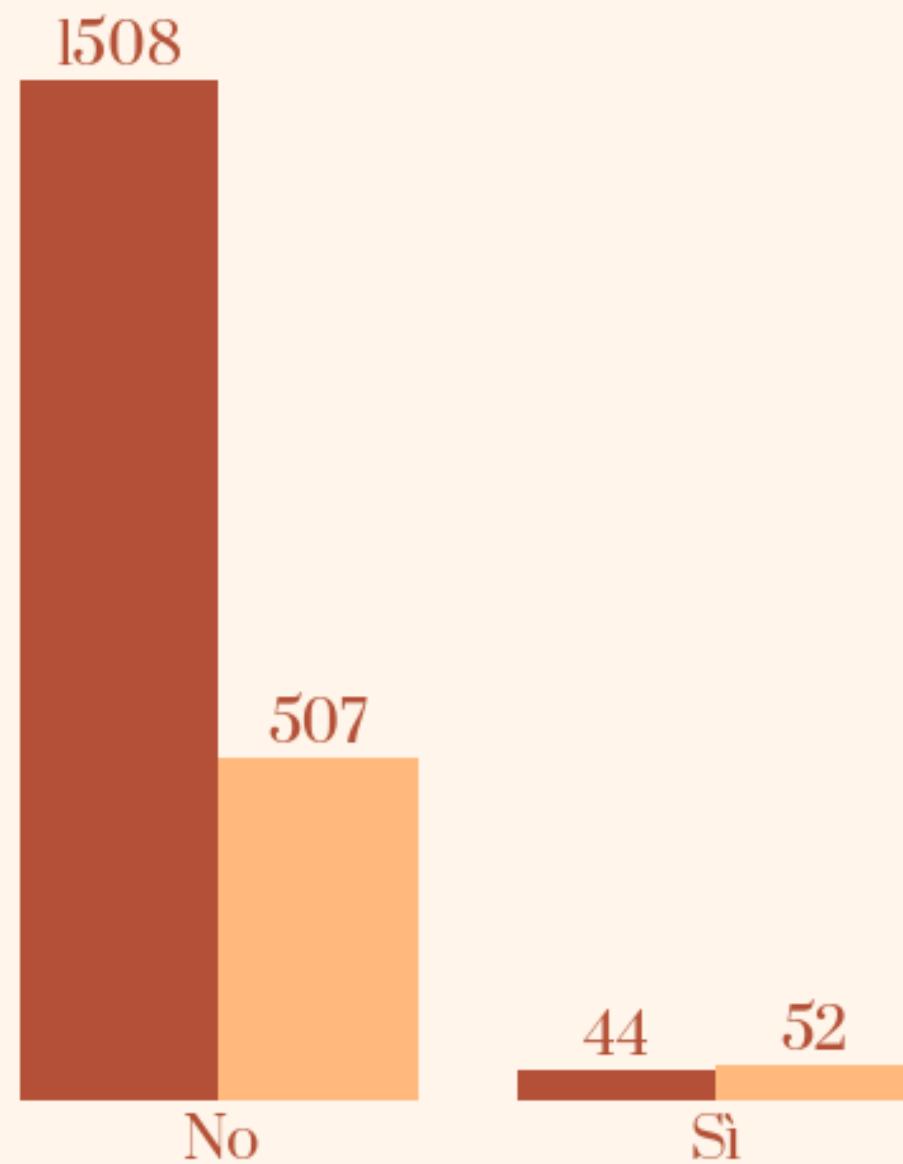
Fumatore



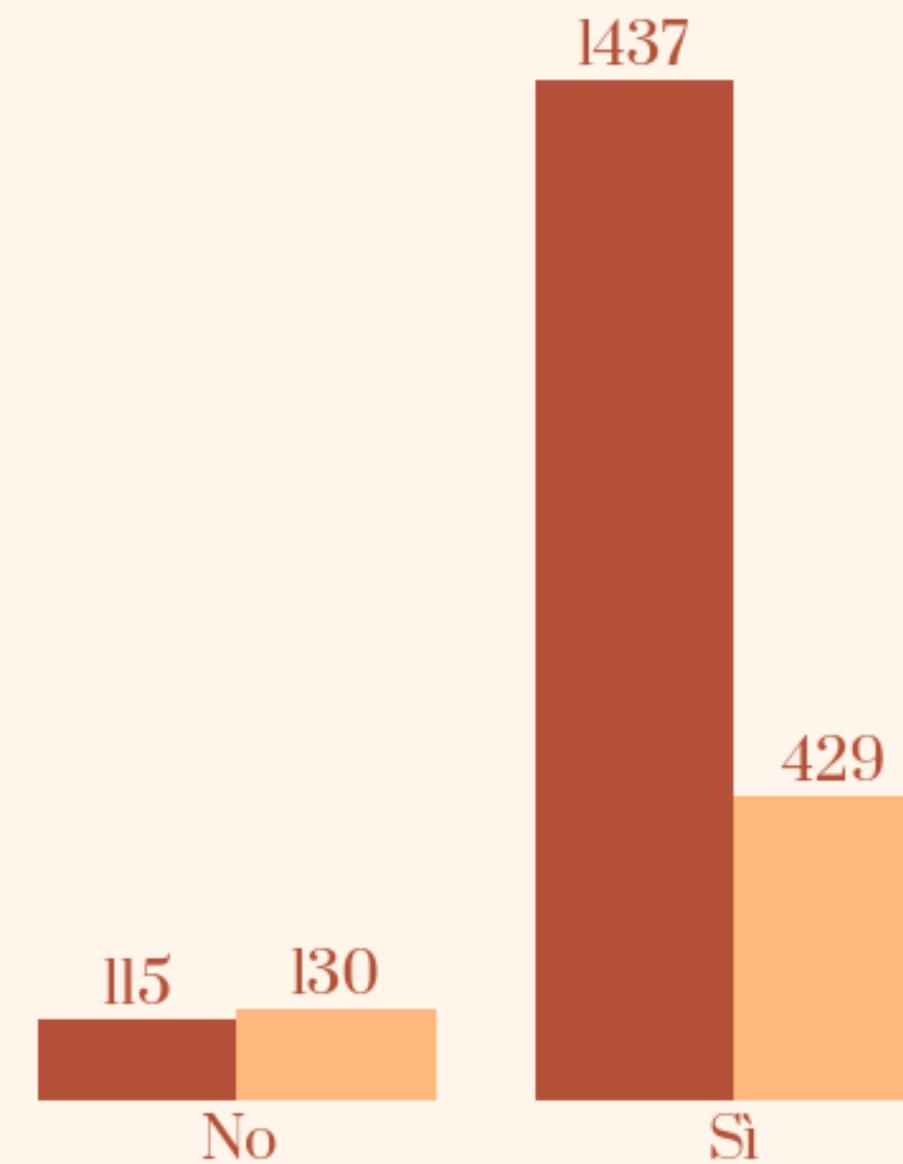
FEATURE BINARIE

Categoria
Sovrappeso/Obeso
Normopeso/Sottopeso

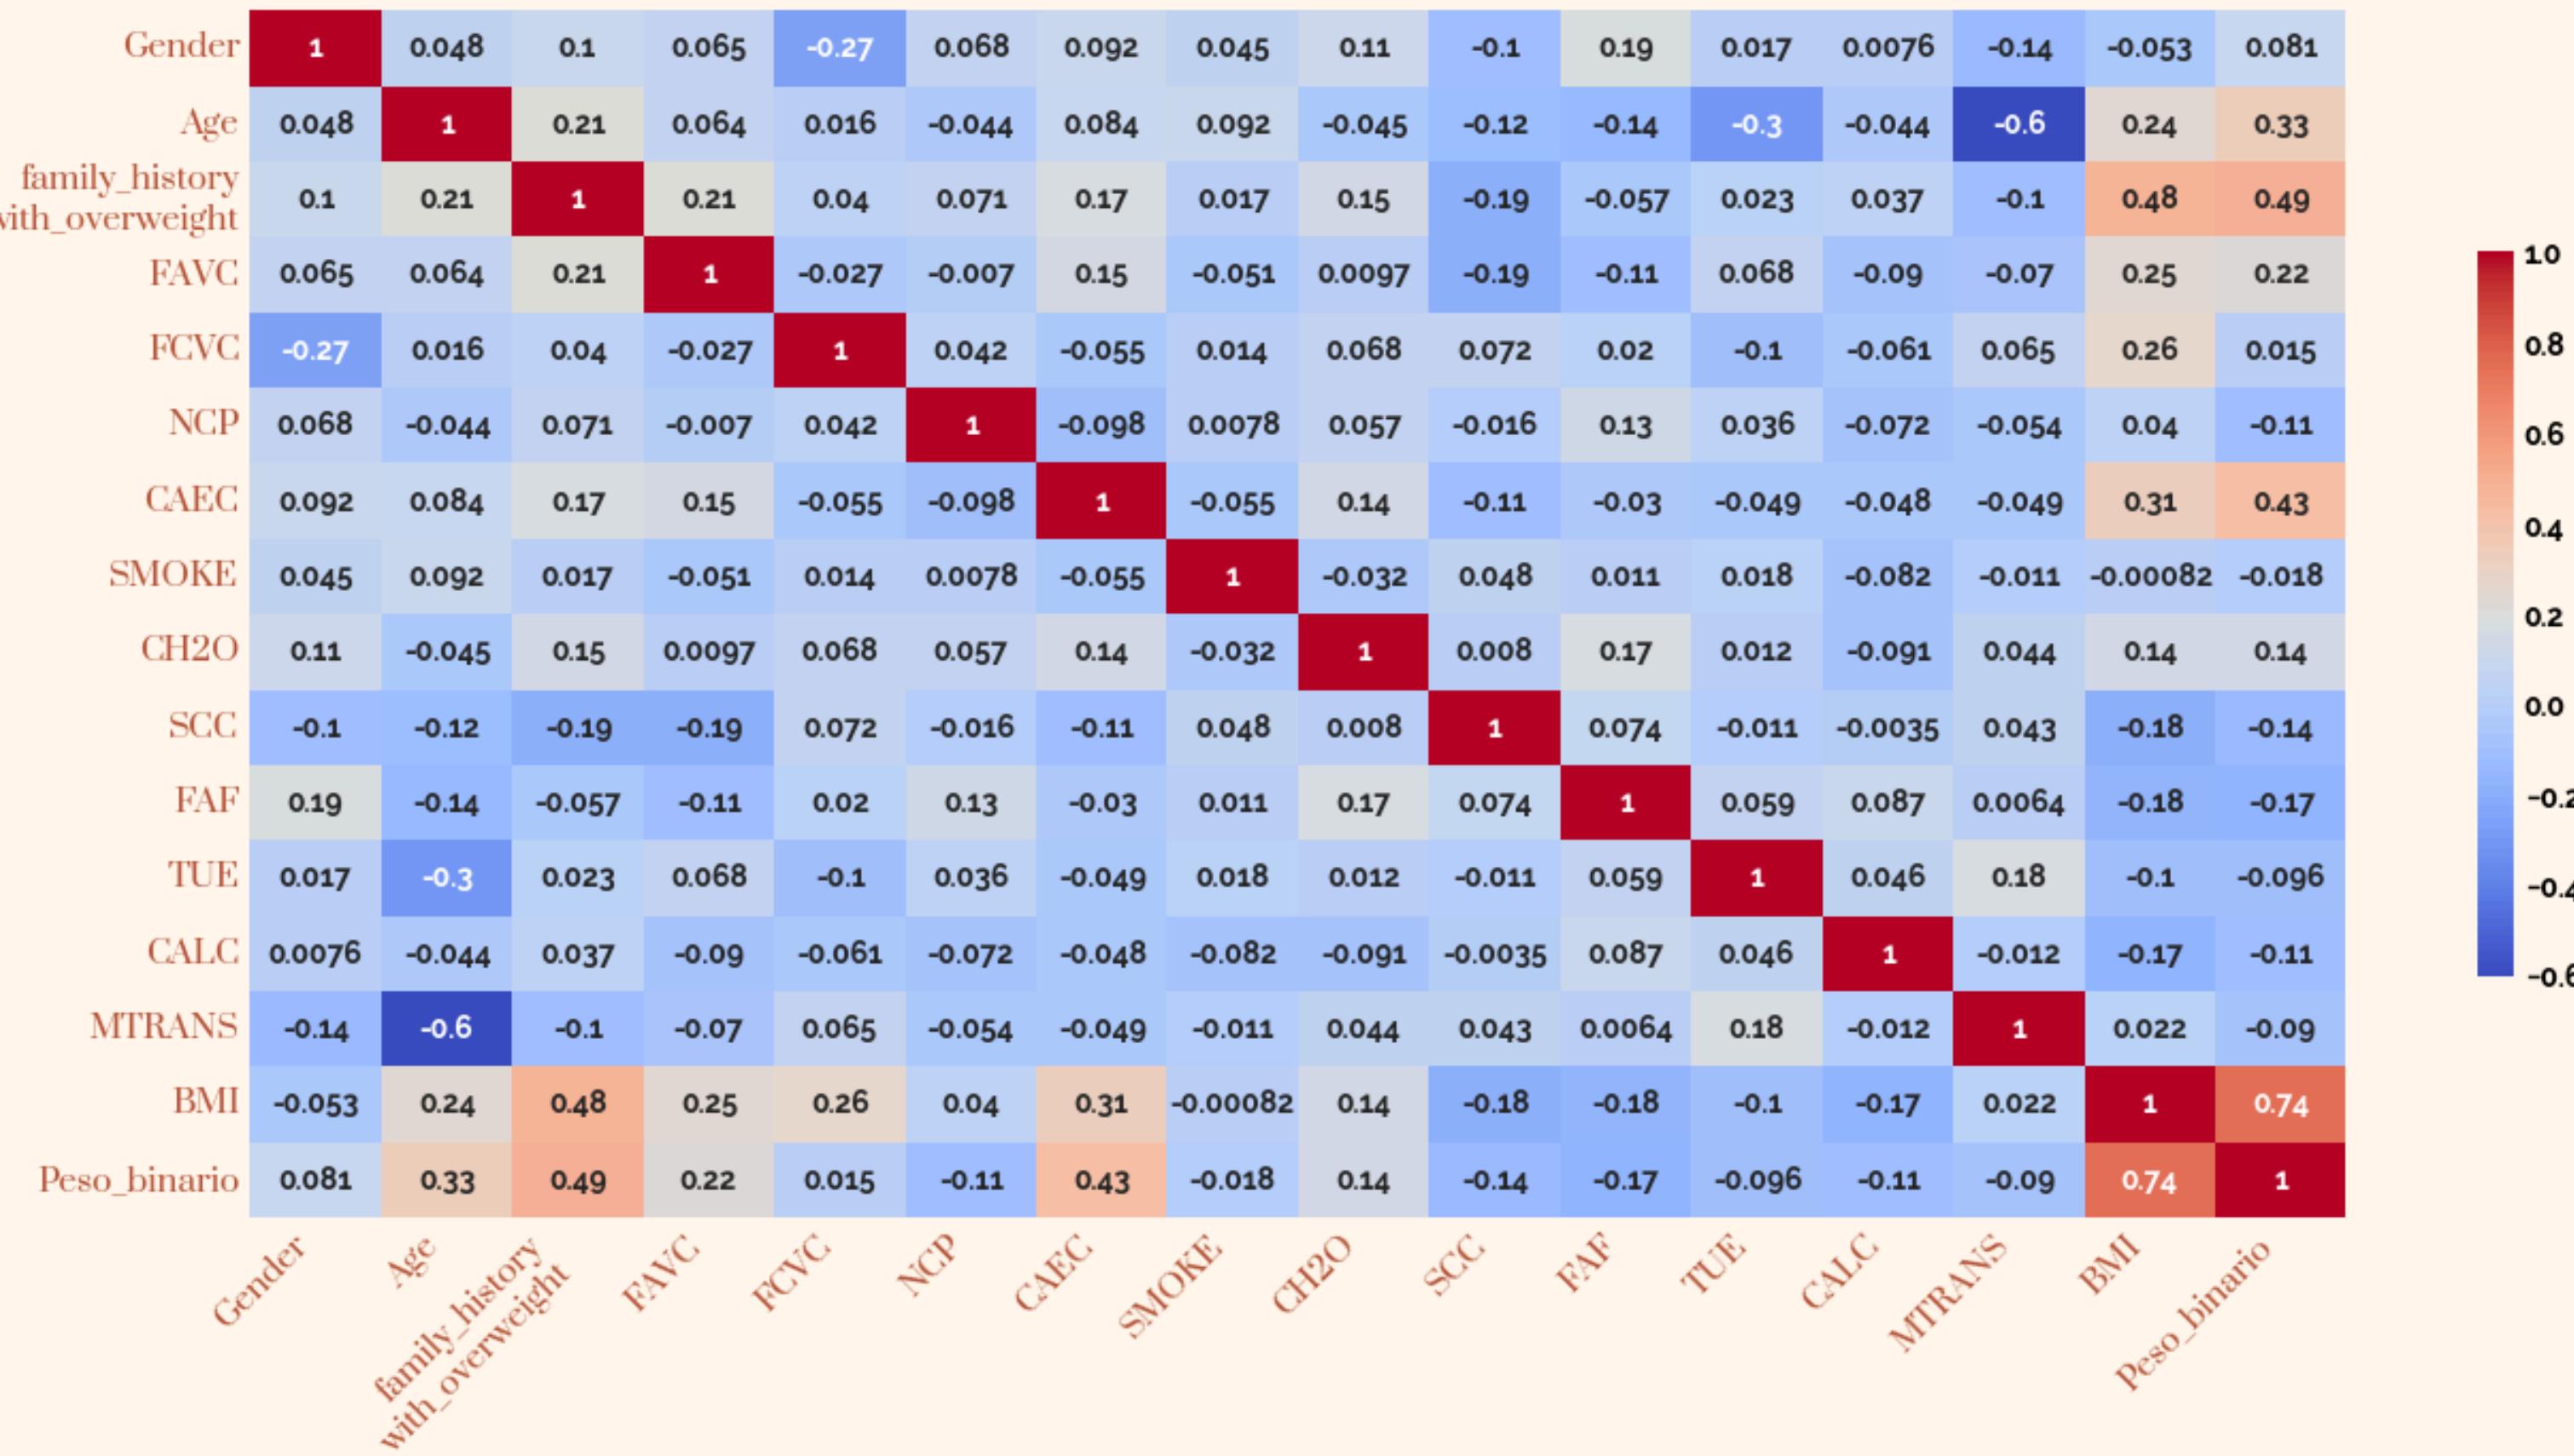
Controllo delle calorie giornaliero



Consumazione di cibo altamente calorici



HEATMAP



CLASSIFICAZIONE

TRAMITE RANDOM FOREST



SUDDIVISIONE

La prima cosa effettuata è stato suddividere il dataset in due parti, training e testing. Le percentuali sono le seguenti, elencate come sono state scritte:



IPERPARAMETRI

IPERPARAMETRO	VALORE	SIGNIFICATO
n_estimators	100	Indica il numero di alberi da generare
max_depth	None	Controlla la massima profondità che l'albero può raggiungere.
min_samples_split	5	Numero minimo di campioni richiesti affinché un nodo interno (non una foglia) possa essere ulteriormente diviso
min_samples_leaf	1	Numero minimo di campioni richiesti per trovarsi in un nodo foglia
random_state	3	Serve per ottenere gli stessi alberi ogni volta che vengono eseguiti

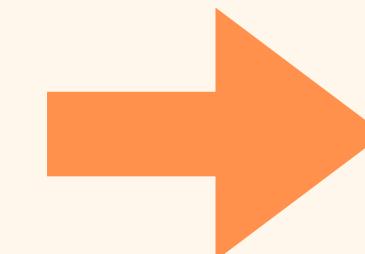
HYPERPARAMETER TUNING

L'hyperparameter Tuning è un processo che mira a trovare la combinazione migliore di iperparametri per migliorare le prestazioni del modello. Gli iperparametri non vengono appresi dal modello ma impostati prima dell'addestramento.

Nel nostro caso abbiamo utilizzato la tecnica del **Grid Search**.

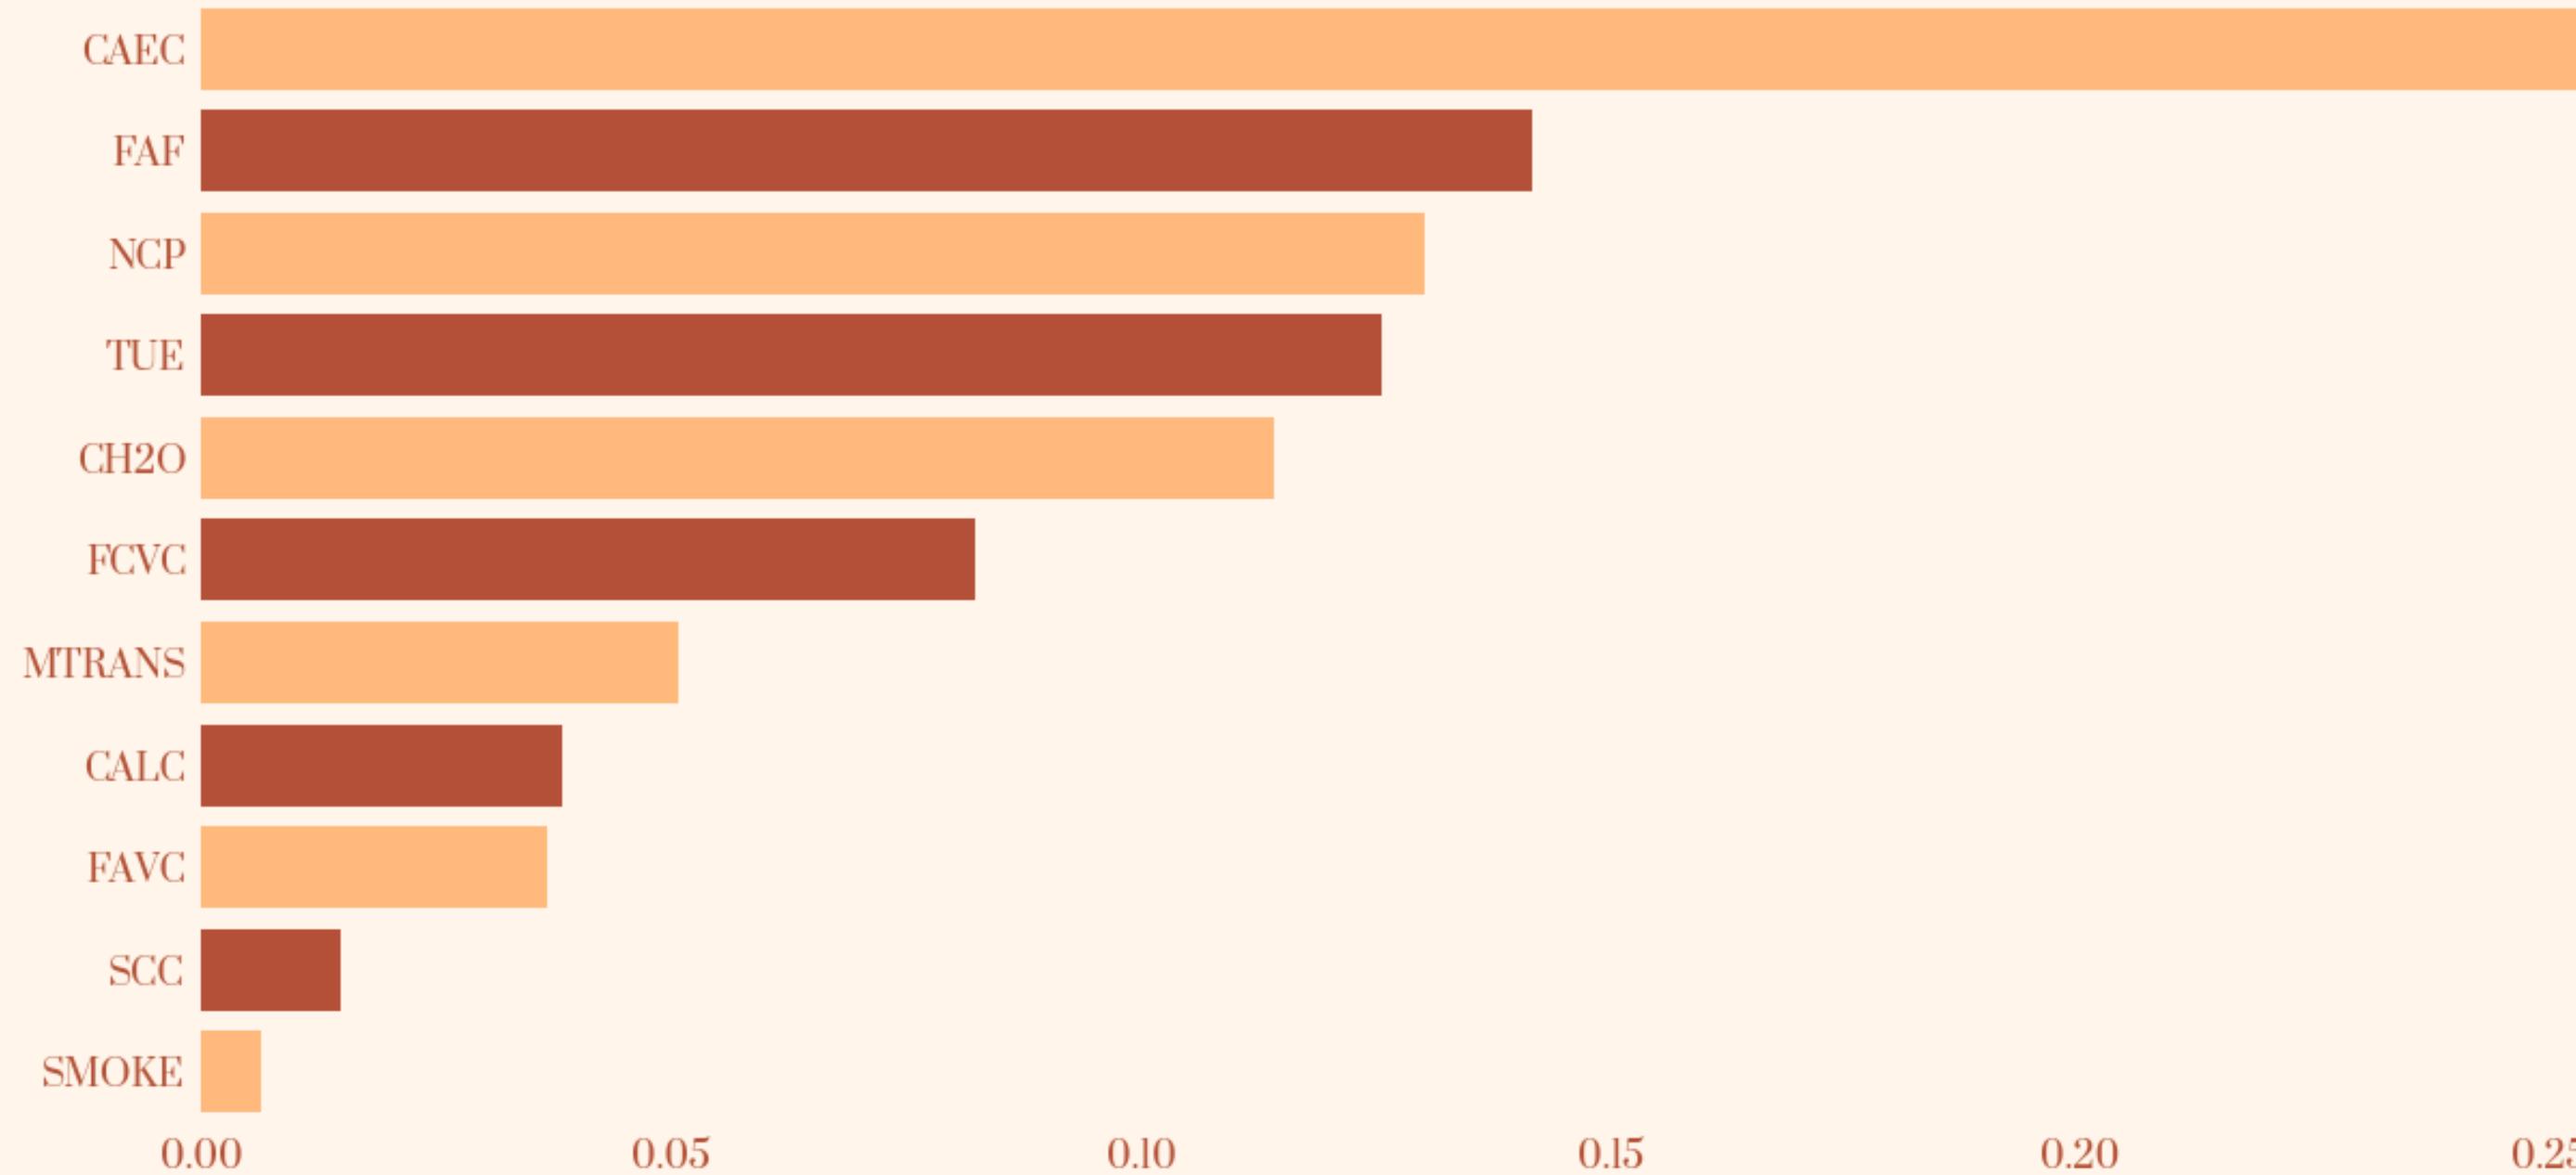
Essa consiste nel testare sistematicamente tutte le combinazioni possibili di un insieme predefinito di iperparametri

```
param_grid = {  
    'n_estimators': [50, 100, 200],  
    'max_depth': [5, 10, 15, None],  
    'min_samples_split': [2, 5, 10],  
    'min_samples_leaf': [1, 2, 4]  
}
```



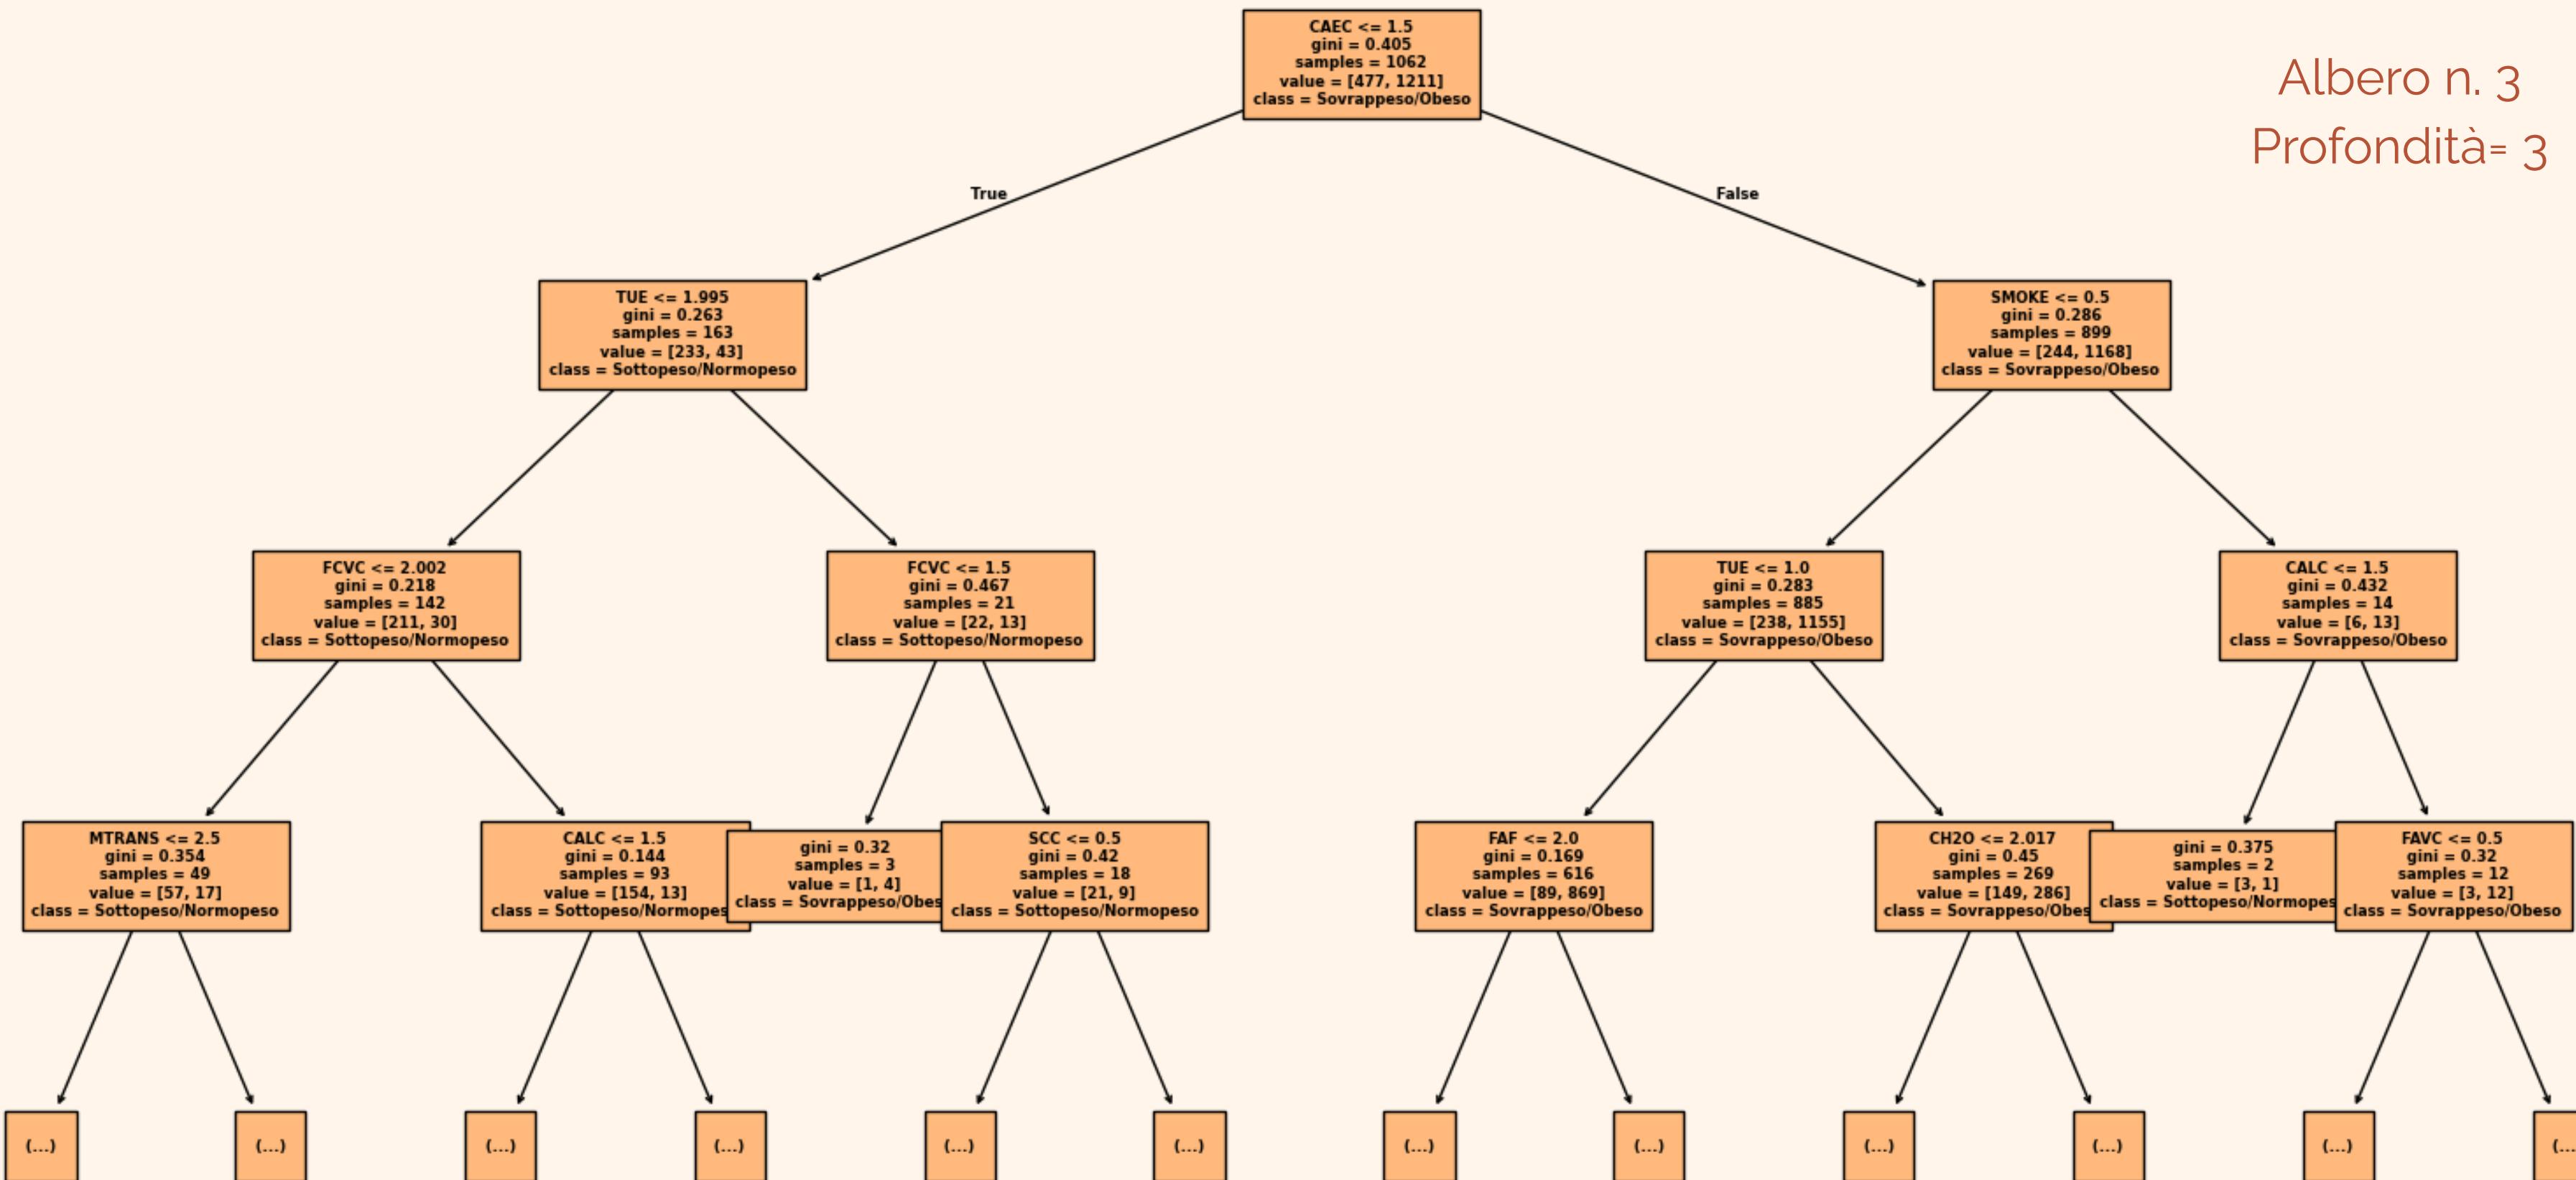
**108
possibili modelli**

FEATURE IMPORTANCE



DECISION TREE

Albero n. 3
Profondità= 3



VALUTAZIONE



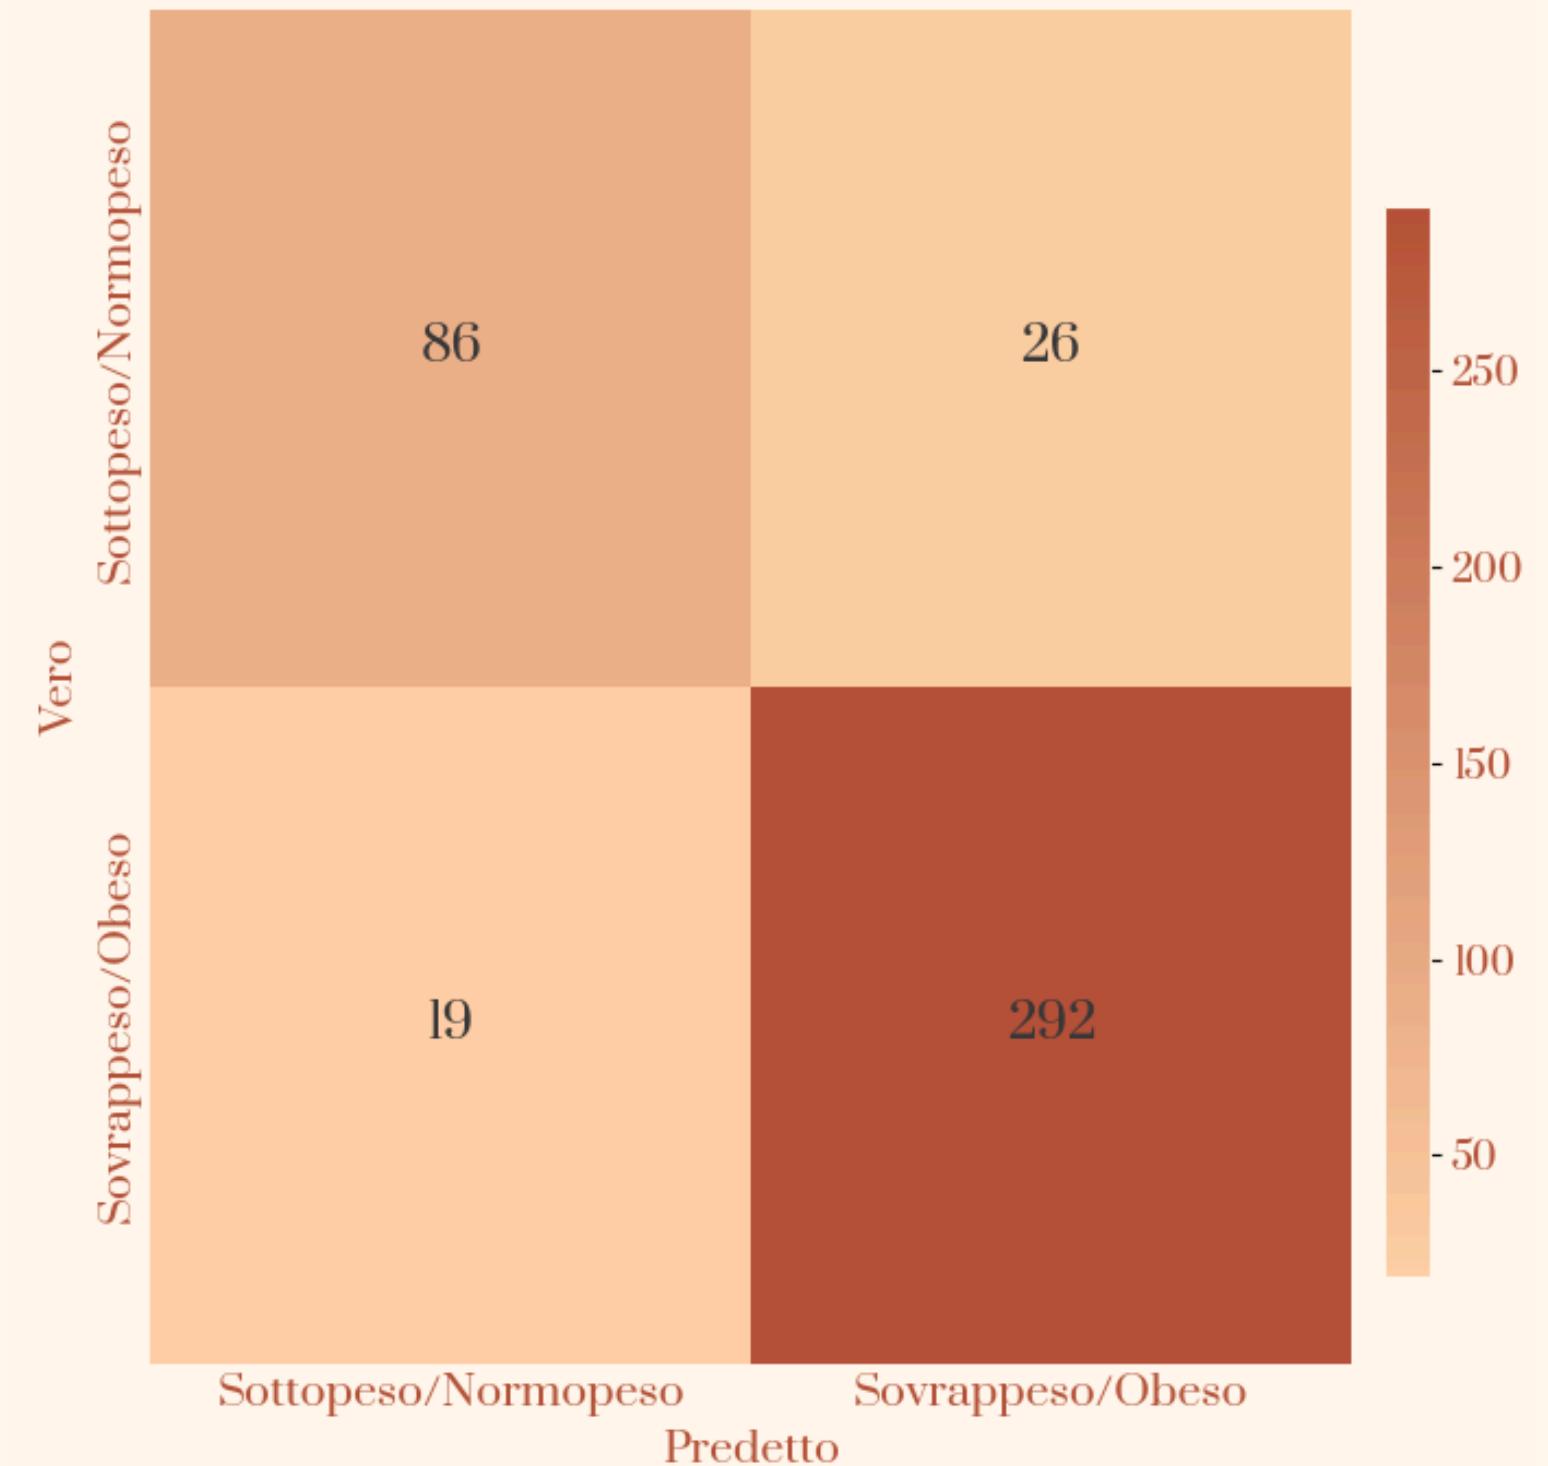
METRICHE

Precision	Percentuale di predizioni positive corrette sul totale delle predizioni positive	$\frac{Tp}{Tp + Fp}$
Recall	Percentuale di casi positivi correttamente individuati dal modello sul totale dei positivi reali	$\frac{Tp}{Tp + Fn}$
F1 Score	Quantifica l'efficacia del modello nel riconoscere la classe positiva minimizzando falsi positivi e falsi negativi. Metrica utile quando si hanno classi sbilanciate	$\frac{2Tp}{2Tp + Fp + Fn}$
ROC	Rappresenta la relazione tra TPR e FPR al variare della soglia di decisione	$TPR = \frac{Tp}{Tp + Fn}$ $FPR = \frac{Fp}{Fp + Tn}$
ROC-AUC	Area sotto la curva ROC e valuta il modello nel complesso	
Accuracy	Percentuale di predizioni corrette sul totale delle predizioni	$\frac{Tp + Tn}{Tp + Tn + Fp + Fn}$

VALUTAZIONE MODELLO

	Precision	Recall	F1 Score	Support
Sottopeso/Normopeso	0.82	0.77	0.79	112
Sovrappeso/Obeso	0.92	0.94	0.93	311
Macro Avg	0.87	0.85	0.86	423
Weighted Avg	0.89	0.89	0.89	423

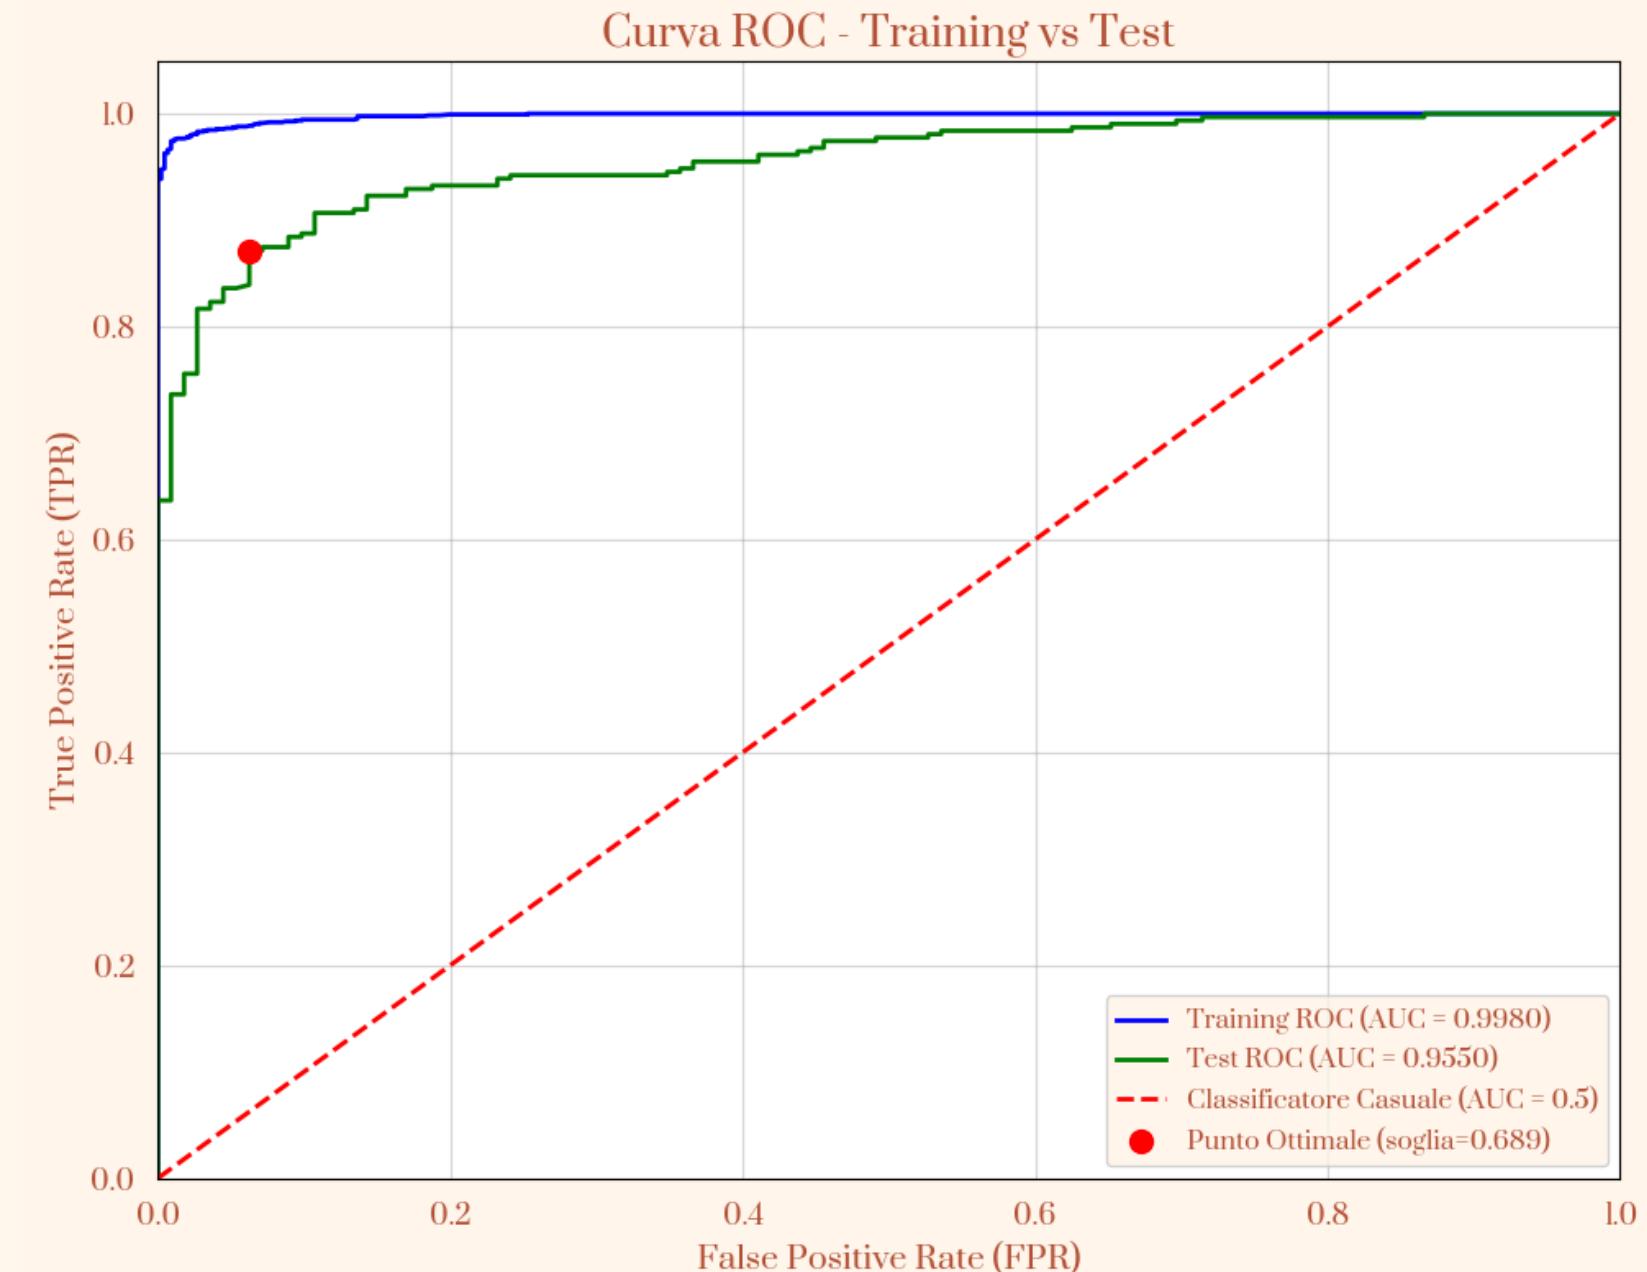
Accuracy: 0.8936



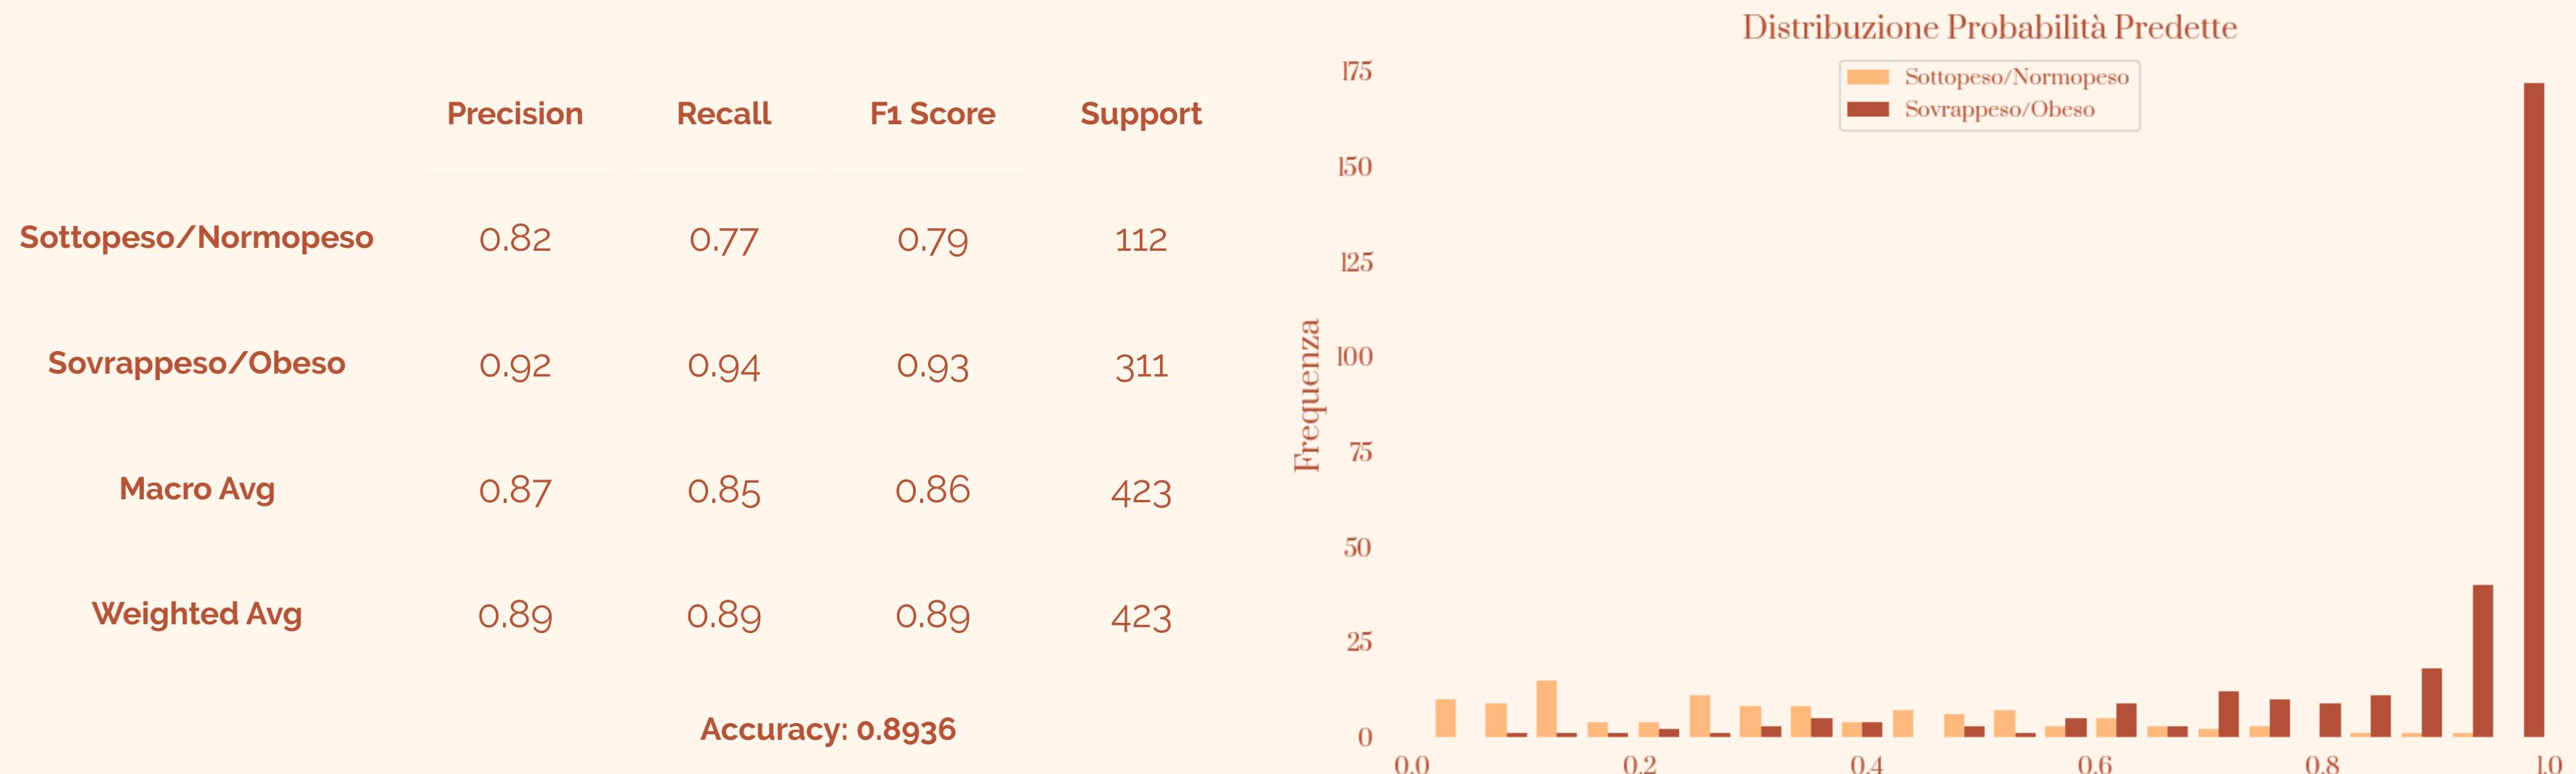
VALUTAZIONE MODELLO

	Precision	Recall	F1 Score	Support
Sottopeso/Normopeso	0.82	0.77	0.79	112
Sovrappeso/Obeso	0.92	0.94	0.93	311
Macro Avg	0.87	0.85	0.86	423
Weighted Avg	0.89	0.89	0.89	423

Accuracy: 0.8936



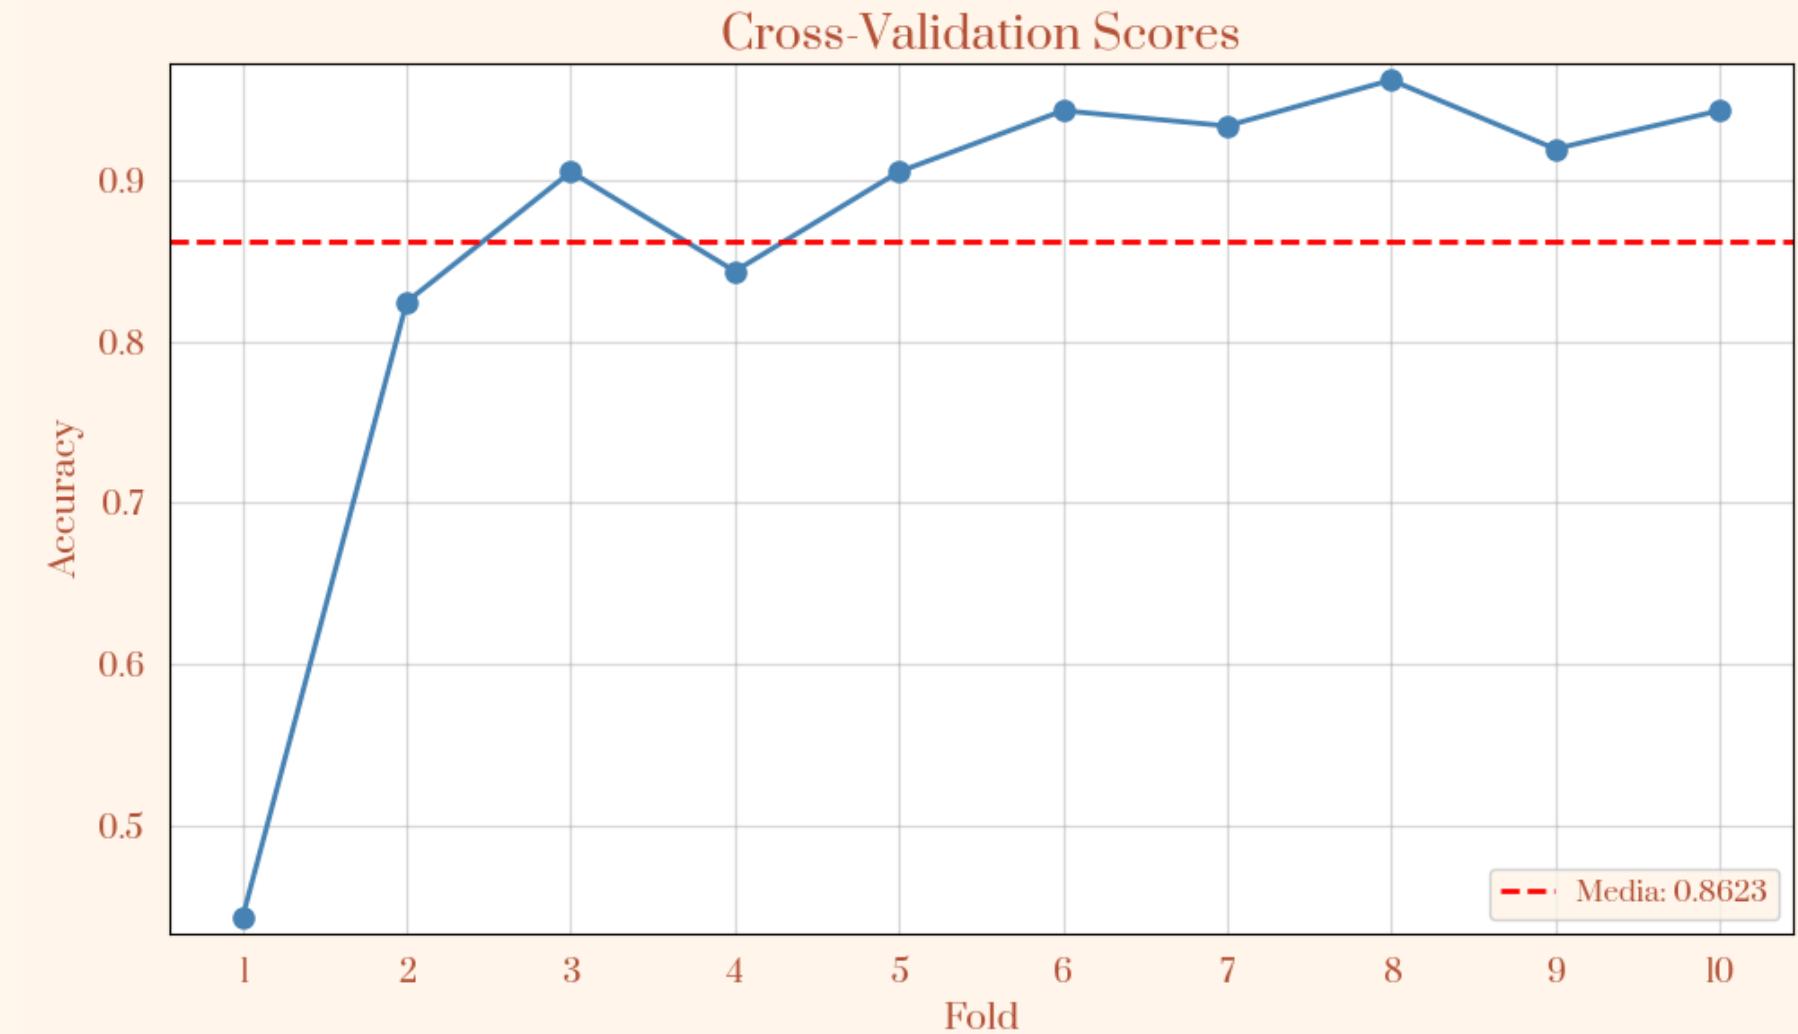
VALUTAZIONE MODELLO



VALUTAZIONE MODELLO

	Precision	Recall	F1 Score	Support
Sottopeso/Normopeso	0.82	0.77	0.79	112
Sovrappeso/Obeso	0.92	0.94	0.93	311
Macro Avg	0.87	0.85	0.86	423
Weighted Avg	0.89	0.89	0.89	423

Accuracy: 0.8936



Fine